


REGRESI LOGISTIK

**Mata kuliah:
TI5002 Analisis Statistik
Minggu ke-3**



Pengantar

- Regresi linear majemuk mensyaratkan variabel dependen adalah berskala metrik
- Permasalahan timbul saat variabel dependen berskala nonmetrik, misalnya nominal (sukses vs gagal).
- Hal ini disebabkan satu asumsi regresi linear, i.e normalitas error, dilanggar (why?)

Ilustrasi: Data


Sumber: Hosmer & Lemeshow (2000)

Berikut data 100 orang, meliputi usia dan apakah terdapat tanda gangguan penyakit jantung atau tidak.

ID	AGE	AGRP	CHD	ID	AGE	AGRP	CHD
1	20	1	0	51	44	4	1
2	23	1	0	52	44	4	1
3	24	1	0	53	45	5	0
4	25	1	0	54	45	5	1
5	25	1	1	55	46	5	0
6	26	1	0	56	46	5	1
7	26	1	0	57	47	5	0
8	28	1	0	58	47	5	0
9	28	1	0	59	47	5	1
10	29	1	0	60	48	5	0
11	30	2	0	61	48	5	1
12	30	2	0	62	48	5	1

Ilustrasi: Scattered Plot

Sumber: Hosmer & Lemeshow (2000)



Ilustrasi: Pengelompokan Data


Sumber: Hosmer & Lemeshow (2000)


Table 1.2 Frequency Table of Age Group by CHD

Age Group	<i>n</i>	CHD		Mean (Proportion)
		Absent	Present	
20 – 29	10	9	1	0.10
30 – 34	15	13	2	0.13
35 – 39	12	9	3	0.25
40 – 44	15	10	5	0.33
45 – 49	13	7	6	0.46
50 – 54	8	3	5	0.63
55 – 59	17	4	13	0.76
60 – 69	10	2	8	0.80
Total	100	57	43	0.43

Ilustrasi: Plot Data Dikelompokkan

Sumber: Hosmer & Lemeshow (2000)






Ilustrasi: Fungsi Logistik

- Berdasarkan gambar plot kedua, sumbu Y dapat diganti dengan ekspektasi Y atau persentase responden dengan gejala sakit jantung
- Pada plot kedua ini, dapat dituliskan hubungan antara variabel independen AGE (X) dengan ekspektasi gejala sakit jantung $E(Y|X)$ s.b.b:

$$E(Y|X) = \beta_0 + \beta_1 X$$

- Selanjutnya, jika diperhatikan bentuk plot kedua tidak sepenuhnya linear, tetapi cenderung membentuk huruf S
- Dalam hal ini, salah satu fungsi yang banyak digunakan untuk mendekati bentuk kurva S ini adalah fungsi logistik



Ilustrasi: Transformasi Logit

- Jika $E(Y|X)$ dinotasikan dengan $\pi(x)$, maka

$$\pi(x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$$

- $\pi(x)$ dapat ditransformasikan dengan menggunakan transformasi logit:

$$\begin{aligned} g(x) &= \ln \left[\frac{\pi(x)}{1 - \pi(x)} \right] \\ &= \beta_0 + \beta_1 x . \end{aligned}$$

Properti fungsi transformasi logit

- berbentuk linear
- dapat bernilai kontinyu
- dapat mengambil nilai antara $-\infty$ dan $+\infty$




Estimasi Model Logit (1)

- Untuk mengestimasi parameter β dalam model logit tidak dapat digunakan metode least square seperti pada regresi linier
- Di sini digunakan metode maximum likelihood
- Fungsi likelihood:

$$l(\beta) = \prod_{i=1}^n \pi(x_i)^{y_i} [1 - \pi(x_i)]^{1-y_i}$$

- Di sini akan dicari nilai β yang akan memaksimalkan fungsi likelihood $\ell(\beta)$



Estimasi Model Logit (2)

- Untuk memudahkan diferensiasi, fungsi likelihood di log-kan menjadi fungsi log-likelihood:

$$L(\beta) = \ln[l(\beta)] = \sum_{i=1}^n \left\{ y_i \ln[\pi(x_i)] + (1 - y_i) \ln[1 - \pi(x_i)] \right\}$$

- Dengan menggunakan kalkulus akan didapatkan nilai maksimum fungsi log-likelihood akan dicapai pada β yang memenuhi persamaan berikut:

$$\sum [y_i - \pi(x_i)] = 0 \quad \text{dan} \quad \sum x_i [y_i - \pi(x_i)] = 0$$

- Solusi untuk kedua persamaan tersebut dapat diperoleh dengan menggunakan metode numerik, dan dapat menggunakan software statistika untuk memperolehnya

Ilustrasi: Solusi

Sumber: Hosmer & Lemeshow (2000)

Variable	Coeff.	Std. Err.	z	P> z
AGE	0.111	0.0241	4.61	<0.001
Constant	-5.309	1.1337	-4.68	<0.001

Log likelihood = -53.67656

$$\hat{\pi}(x) = \frac{e^{-5.309+0.111 \times \text{AGE}}}{1 + e^{-5.309+0.111 \times \text{AGE}}}$$

$$\hat{g}(x) = -5.309 + 0.111 \times \text{AGE}$$

Penqujian signifikansi

Pengujian signifikansi parameter model logit (1)

- Menggunakan argumentasi yang mirip pada analisis regresi linear: “Apakah model dengan variabel independen yang diuji memberikan informasi lebih banyak tentang variabel dependen dibandingkan dengan model yang tanpa variabel independen tersebut”
- Untuk melakukan perbandingan ini digunakan statistik ***deviance***:

$$D = -2 \ln \left[\frac{(\text{likelihood of the fitted model})}{(\text{likelihood of the saturated model})} \right]$$

Catatan: model saturated adalah model dengan jumlah parameter sama dengan jumlah data point

parameter sama dengan jumlah data point

Pengujian signifikansi parameter model logit (2)

- Dalam kasus logit di atas, diperoleh:

$$D = -2 \sum_{i=1}^n \left[y_i \ln \left(\frac{\hat{\pi}_i}{y_i} \right) + (1 - y_i) \ln \left(\frac{1 - \hat{\pi}_i}{1 - y_i} \right) \right]$$

- Selanjutnya, dapat dibuktikan:

$$D = -2 \ln(\text{likelihood of the fitted model})$$


- Perubahan D dari model tanpa variabel yang diuji ke model dengan variabel yang diuji dapat dituliskan sebagai:

$$G = D(\text{model without the variable}) - D(\text{model with the variable})$$

$$G = -2 \ln \left[\frac{(\text{likelihood without the variable})}{(\text{likelihood with the variable})} \right]$$

Pengujian signifikansi parameter model logit (2)

- Dengan hipotesis $\beta_1 = 0$, G akan berdistribusi chi-square dengan d.o.f = 1
- Pada contoh kasus, di dapat nilai fungsi log-likelihood pada model tanpa variabel x adalah -68,331 sehingga dapat disimpulkan parameter untuk variabel x (β_1) adalah signifikan.




Uji signifikansi dengan Statistik Wald (W)

- Cara alternatif menguji signifikansi parameter model logit adalah dengan menggunakan statistik Wald:

$$W = \frac{\hat{\beta}_1}{\widehat{SE}(\hat{\beta}_1)}$$

- Statistik W akan berdistribusi normal secara asimptotis



Ukuran Keباikan Model Logit

Untuk ukuran kebaikan model logit, dapat digunakan pseudo R^2_{logit}


$$R^2_{\text{logit}} = \frac{-2LL_{\text{null}} - (-2LL_{\text{model}})}{-2LL_{\text{null}}}$$

Selain itu, terdapat pula beberapa statistik goodness-of-fit yang lain seperti Hosmer-Lemeshow statistic.

Interpretasi parameter model logit


- Interpretasi parameter model logit mirip interpretasi parameter pada model regresi linear majemuk
- Jika parameter sebuah variabel signifikan berbeda dari nol, artinya variabel ini berpengaruh terhadap probabilitas $Y = y$.
- Secara khusus, fungsi logistik ($=e^{\beta' \mathbf{x}}$) menggambarkan apa yang disebut dengan odds ratio atau perbandingan

$$\frac{\text{Probabilitas}(Y = 1)}{\text{Probabilitas}(Y = 0)}$$



Model Logit Lanjut

- Jika outcome lebih dari dua, maka dapat digunakan model multinomial logit ataupun ordered multinomial logit (jika Y ordinal)
- Referensi lebih lanjut:
 1. Hosmer & Lemeshow (2000). *Applied Logistic Regression*
 2. Paap & Franses (2004). *Quantitative Models in Marketing*.



Contoh Kasus

Setiap tahunnya pemerintah mengundang swasta untuk berpartisipasi dalam proyek pemerintah. Namun tidak semua perusahaan yang diundang menyatakan berminat untuk turut berpartisipasi. Pemerintah telah mencatat data perusahaan yang berminat dan tidak berminat terkait dengan ukuran (jumlah karyawan), pendapatan tahunan (juta USD), usia perusahaan (tahun) dan jumlah proyek dalam setahun (buah).

Pemerintah ingin mengetahui apakah variabel-variabel tersebut dapat digunakan untuk memprediksi apakah sebuah perusahaan berminat untuk berpartisipasi dalam proyek pemerintah? Bagaimana model yang bisa digunakan untuk memprediksi minat ini?

Contoh Kasus

(potongan data: n=60)

ukrn	pdptn	usia	jmlproy	minat
54.00	4.00	6.50	7.00	2.00
45.00	2.00	6.00	6.00	1.00
44.00	2.00	5.80	11.00	1.00
46.00	1.00	7.00	3.00	2.00
46.00	3.00	6.50	8.00	2.00
37.00	.90	5.00	2.00	1.00
42.00	.90	5.00	2.00	1.00
29.00	3.60	6.50	3.00	1.00
46.00	.90	6.00	5.00	1.00
28.00	.90	6.00	2.00	1.00
39.00	3.60	7.00	3.00	2.00
31.00	4.00	7.00	3.00	1.00
65.00	1.00	7.00	9.00	2.00
50.00	1.00	7.00	9.00	1.00
30.00	2.00	7.50	3.00	2.00
58.00	1.00	6.00	5.00	2.00
54.00	2.00	6.50	4.00	1.00
58.00	1.00	7.00	9.00	2.00

Contoh Kasus

(Model 0 tanpa variable independent)

Classification Table^{a,b}

Observed			Predicted		
			minat		Percentage Correct
			1.00	2.00	
Step 0	minat	1.00	38	0	100.0
		2.00	22	0	.0
Overall Percentage					63.3

a. Constant is included in the model.

b. The cut value is .500

Variables in the Equation

	B	S.E.	Wald	df	Sig.	Exp(B)
Step 0 Constant	-.547	.268	4.162	1	.041	.579

Contoh Kasus (hasil metode enter)

Variables in the Equation


	B	S.E.	Wald	df	Sig.	Exp(B)
Step 1 ^a						
ukrn	.089	.039	5.109	1	.024	1.093
pdptn	.161	.351	.211	1	.646	1.175
usia	.914	.394	5.376	1	.020	2.494
jmlproy	-.020	.159	.016	1	.900	.980
Constant	-10.397	3.280	10.045	1	.002	.000

a. Variable(s) entered on step 1: ukrn, pdptn, usia, jmlproy.

Model Summary

Step	-2 Log likelihood	Cox & Snell R Square	Nagelkerke R Square
1	65.478 ^a	.200	.273

a. Estimation terminated at iteration number 5 because parameter estimates changed by less than .001.



Contoh Kasus

Classification Table^a

Observed			Predicted		
			minat		Percentage Correct
			1.00	2.00	
Step 1	minat	1.00	32	6	84.2
		2.00	12	10	45.5
Overall Percentage					70.0

a. The cut value is .500

Contoh Kasus

Variables in the Equation

		B	S.E.	Wald	df	Sig.	Exp(B)
Step 1 ^a	ukrn	.064	.028	5.203	1	.023	1.066
	Constant	-3.328	1.268	6.884	1	.009	.036
Step 2 ^b	ukrn	.084	.031	7.541	1	.006	1.088
	usia	.934	.390	5.749	1	.016	2.546
	Constant	-10.158	3.205	10.046	1	.002	.000

a. Variable(s) entered on step 1: ukrn.

b. Variable(s) entered on step 2: usia.

Classification Table^a

Observed			Predicted		
			minat		Percentage Correct
			1.00	2.00	
Step 1	minat	1.00	35	3	92.1
		2.00	14	8	36.4
	Overall Percentage				71.7
Step 2	minat	1.00	31	7	81.6
		2.00	9	13	59.1
	Overall Percentage				73.3

a. The cut value is .500