



ANALISIS *CLUSTER*

Mata kuliah:
TI-5002 ANALISIS STATISTIK
Minggu ke-5



TUJUAN


- Tujuan analisis cluster adalah untuk mengelompokkan objek penelitian (orang, perusahaan, atau produk) ke dalam kelompok-kelompok yang *manageable* dengan menggunakan atribut (variabel) pengelompok tertentu.
- Dalam satu kelompok diharapkan anggotanya memiliki sifat kemiripan yang tinggi dan anggota satu kelompok dengan anggota kelompok yang lain diharapkan memiliki perbedaan yang berarti.



Karakteristik

- Deskriptif
- Eksploratori
- Solusi tidak unik
- Selalu dapat menghasilkan cluster, meskipun struktur 'sebenarnya' ada atau tidak
- Sangat tergantung pada variabel pengelompok

Gambaran awal (1)




Gambaran awal (2)

Hair dkk (2010)

Cluster Analysis

Data Values

Clustering Variable	Respondents						
	A	B	C	D	E	F	G
V_1	3	4	4	2	6	7	6
V_2	2	5	7	7	6	7	4




Gambaran awal (3)


Hair dkk (2010)


Cluster Analysis

(a) Nested Groupings



(b) Dendrogram







METODOLOGI

- Pengelompokan pada analisis cluster dapat didasarkan pada kesamaan (*similarity*) atau ketidaksamaan (*dissimilarity*) dari masing-masing objek.
- Proses dimulai dengan pengambilan p pengukuran variabel dan n objek pengamatan (matriks $n \times p$). matriks tersebut ditransformasikan ke dalam bentuk matriks similaritas berukuran $n \times n$ yang dihitung berdasarkan pasangan-pasangan obyek p variabel.
- Kemudian suatu algoritma pengelompokan dipilih
- Terdapat dua pendekatan dalam algoritma pengelompokan, yaitu pendekatan hierarkis (*hierarchical clustering*) dan pendekatan non-hierarkis (*nonhierarchical clustering*).

Matriks Jarak Euclidean




Matriks Koordinat (n x p)

Object	V1	V2
A	3	2
B	4	5
C	4	7
D	2	7
E	6	6
F	7	7
G	6	4




Matriks Jarak (p x p)

	A	B	C	D	E	F	G
A	0	3.16	5.10	5.10	5.00	6.40	3.61
B		0.00	2.00	2.83	2.24	3.61	2.24
C			0.00	2.00	2.24	3.00	3.61
D				0.00	4.12	5.00	5.00
E					0.00	1.41	2.00
F						0.00	3.16
G							0.00




UKURAN SIMILARITAS

- ukuran jarak
- koefisien korelasi
- koefisien asosiasi



PENDEKATAN CLUSTERING


1. Teknik hierarkis
 - top down (decision)
 - bottom up (agglomerative)
2. Teknik non-hierarkis
3. Teknik kombinasi





METODE PENGELOMPOKAN HIERARKIS

- *Single Linkage (Nearest Neighbor Methods).*
- *Complete Linkage (Furthest Neighbor Methods).*
- *Average Linkage Methods (Between-groups Methods).*
- *Ward's Error Sum of Squares Methods.*
- *Metode Centroid.*


METODE PENGELOMPOKAN HIERARKIS




METODE PENGELOMPOKAN HIERARKIS




METODE PENGELOMPOKAN HIERARKIS





TEKNIK PENGELOMPOKAN NON-HIERARKIS


- 1. Sequential Threshold*
- 2. Parallel Treshold*
- 3. Optimizing*



HAL-HAL BERKAITAN DENGAN INPUT ANALISIS CLUSTER


- satuan yang digunakan
- adanya outlier
- variabel-variabel pengelompok
- dependensi antar variabel

JUMLAH CLUSTER YANG DIBENTUK (1)




- peneliti telah menetapkan jumlah cluster yang akan dibentuk.
- didasarkan pada ukuran variabilitas error (deviasi dari pusat cluster) melalui analisis koefisien aglomerasi (lihat contoh di slide berikut).
- didasarkan pada kemudahan interpretasi.

JUMLAH CLUSTER YANG DIBENTUK (2)




INTERPRETASI CLUSTER YANG TERBENTUK

- Setelah cluster terbentuk tugas analisis yang berikutnya adalah mendeskripsikan masing-masing cluster tersebut.
- Salah satu cara mendeskripsikan cluster yang terbentuk adalah dengan menggunakan centroid atau nilai rata-rata masing-masing variabel dari tiap objek yang berada dalam cluster tersebut
- Selanjutnya tiap cluster dapat diberi nama
- Penamaan cluster yang baik harus memperhatikan tujuan studi.



VALIDASI

- membandingkan hasil yang diperoleh dengan algoritma yang berbeda
- membagi sampel menjadi dua
- menggunakan variabel yang tidak digunakan untuk mengelompokkan
- simulasi




HUBUNGAN DENGAN TEKNIK REDUKSI DATA LAINNYA

Analisis Cluster vs Analisis Faktor/Analisis Komponen Utama

- AC: lebih terfokus untuk mereduksi data obyek
- AKU: lebih terfokus untuk mereduksi variabel


Analisis Cluster vs Regresi Logistik/Analisis Diskriminan

- AC: dimulai dengan grup yang belum berdiferensiasi, kemudian grup itu dijadikan sub-grup yang dapat dibedakan
- AD: dimulai dengan grup yang telah jelas (*well defined*) dan yang dipertanyakan adalah bagaimana grup tersebut dibedakan



CONTOH ANALISIS CLUSTER

Pemerintah ingin melihat apakah UKM dapat dikelompokkan menjadi beberapa kelompok berdasarkan ukuran (jumlah karyawan), omzet, usia, dan jumlah produk yang dijual. Untuk itu diambil sampel berukuran 15 perusahaan dan dilakukan analisis cluster.



Contoh Input Analisis Cluster

Tabel 1. Data Perusahaan yang Akan Dikelompokkan

Perusahaan ke-	Jumlah Karyawan	Pendapatan (milyar Rp.)	Usia	Jumlah Produk
1	43	1	7	3
2	54	2.7	7	4
3	49	3.1	3.5	7
4	43	2.52	2.5	2
5	52	5.4	4	7
6	29	1.8	3	6
7	37	3.4	4	2
8	27	2.6	4.5	5
9	20	2	2	3
10	34	1.2	3	3
11	48	1.3	2.5	2
12	53	0.9	6	6
13	41	4.2	6	5
14	47	2.3	7	2
15	30	3.3	5	4


Contoh Output Analisis Cluster

Tabel 2. Agglomeration Schedule Pengelompokan 15 Industri


Stage	Cluster Combined		Coefficients	Stage Cluster First Appears		Next Stage
	Cluster 1	Cluster 2		Cluster 1	Cluster 2	
1	8	15	0.773	0	0	6
2	4	11	1.178	0	0	4
3	1	14	1.524	0	0	5
4	4	10	2.187	2	0	7
5	1	2	2.488	3	0	11
6	6	8	2.693	0	1	9
7	4	7	3.323	4	0	12
8	3	5	3.546	0	0	10
9	6	9	4.263	6	0	12
10	3	13	4.515	8	0	14
11	1	12	4.726	5	0	13
12	4	6	5.621	7	9	13
13	1	4	9.483	11	12	14
14	1	3	10.525	13	10	0

Contoh Output Analisis Cluster

Rescaled Distance Cluster Combine




Gambar 2. Dendrogram Pengelompokan 15 Industri



Contoh Output Analisis Cluster

Tabel 3. Nilai Centroid dari masing-masing Cluster

Cluster	Jumlah Karyawan	Pendapatan (milyar Rp.)	Usia Perush.	Jumlah Produk
Cluster 1 (4,6,7,8,9,10,11,15)	33.50	2.27	3.31	3.38
Cluster 2 (1,2,12, dan 14)	49.25	1.73	6.75	3.75
Cluster 3 (3, 5, dan 13)	47.33	4.23	4.50	6.33



Interpretasi Cluster

- Cluster 1: perusahaan yang baru berkembang
- Cluster 2: perusahaan yang mulai menurun performansinya
- Cluster 3: perusahaan yang sedang berkembang