



REGRESI LINIER MAJEMUK



Mata kuliah:
TI5002 Analisis Statistik
Minggu ke-2



BAGIAN I:

SPESIFIKASI DAN KALKULASI PARAMETER/UKURAN FITNESS MODEL

Model Umum

Regresi linier majemuk merupakan generalisasi dari regresi linier sederhana dan memiliki model umum:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon$$

Contoh

$$IP = \beta_0 + \beta_1 JamBel + \beta_2 TOEFL + \beta_3 Gender + \varepsilon$$

Tapi apakah hanya ada tiga variabel yang mempengaruhi IP?

Interpretasi ε

Model yang Di-*fit*-kan

- Model regresi di atas dapat didekati dengan menggunakan data sampel sehingga didapatkan model yang di-fit-kan:

$$\hat{Y} = b_0 + b_1X_1 + b_2X_2 + \dots + b_kX_k$$

Residual pada Model yang Di-fit-kan

$$SSE = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - b_0 - b_1 x_{1i} - b_2 x_{2i} - b_k x_{ki})^2$$

Dengan mendiferensiasi SSE terhadap $b_0, b_1, \dots, b_k$ akan didapatkan:

$$\begin{array}{ccccccc} nb_0 + b_1 \sum_{i=1}^n x_{1i} & + b_2 \sum_{i=1}^n x_{2i} & + \dots + b_k \sum_{i=1}^n x_{ki} & = & \sum_{i=1}^n y_i \\ b_0 \sum_{i=1}^n x_{1i} + b_1 \sum_{i=1}^n x_{1i}^2 & + b_2 \sum_{i=1}^n x_{1i} x_{2i} & + \dots + b_k \sum_{i=1}^n x_{1i} x_{ki} & = & \sum_{i=1}^n x_{1i} y_i \\ \vdots & \vdots & \vdots & & \vdots \\ b_0 \sum_{i=1}^n x_{ki} + b_1 \sum_{i=1}^n x_{ki} x_{1i} & + b_2 \sum_{i=1}^n x_{ki} x_{2i} & + \dots + b_k \sum_{i=1}^n x_{ki}^2 & = & \sum_{i=1}^n x_{ki} y_i \end{array}$$

Penyelesaian dengan Menggunakan Matriks

$$SSE = (\mathbf{y} - \mathbf{Xb})(\mathbf{y} - \mathbf{Xb})$$

- Untuk meminimalkan SSE :

$$\frac{\partial}{\partial \mathbf{b}} (SSE) = \mathbf{0}$$

- Solusi yang akan didapatkan adalah:

$$\begin{aligned}(\mathbf{X}'\mathbf{X})\mathbf{b} &= \mathbf{X}'\mathbf{y} \\ \mathbf{b} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}\end{aligned}$$

(Verifikasilah ukuran vector & matriks!)

Partisi Variasi

Source	Sum of Squares	d.f.
Regression	$\sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \mathbf{y}'[\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' - \mathbf{1}(\mathbf{1}'\mathbf{1})^{-1}\mathbf{1}]\mathbf{y}$	k
Error	$\sum_{i=1}^n (y_i - \hat{y}_i)^2 = \mathbf{y}'[\mathbf{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}']\mathbf{y}$	$n - (k + 1)$
Total	$\sum_{i=1}^n (y_i - \bar{y})^2 = \mathbf{y}'[\mathbf{I}_n - \mathbf{1}(\mathbf{1}'\mathbf{1})^{-1}\mathbf{1}']\mathbf{y}$	$n - 1$


- k = jumlah variable independent
- n = jumlah sampel
- $\mathbf{I}_n$ = matriks identitas berukuran n
- $\mathbf{1}$ = vector 1 berukuran $n \times 1$
- $\mathbf{X}$ = matriks berukuran $n \times k+1$, kolom pertama vector 1
- $\mathbf{y}$ = vector y berukuran $n \times 1$
- Mean Square .. = $SS../d.f$
- $MSE = s^2$

Standard error parameter hasil estimasi

- Ada $k+1$ parameter yang diestimasi (why +1?)
- Standard error dari vector $\mathbf{b}' = [b_0, b_1, b_2, \dots, b_k]$, dapat dicari dari rumus:

$$\hat{\sigma}_b^2 = s^2(\mathbf{X}'\mathbf{X})^{-1}$$

Di mana $\hat{\sigma}_b^2$ adalah vector standard error untuk estimasi atas $\mathbf{b}$



Tugas Perhitungan Regresi Linear Majemuk dengan operasi matriks/vektor

Tujuan:

1. Mahasiswa memahami prinsip dasar perhitungan estimasi parameter-parameter dan statistic untuk inferensi model regresi linear majemuk
2. Mahasiswa dapat melakukan perhitungan manual (dibantu MS-Excel) analisis regresi linear majemuk melalui operasi matriks/vektor

Tugas Perhitungan Regresi Linear Majemuk dengan operasi matriks/vektor

Tinjau kembali data IP, jam belajar, dan gender mahasiswa berikut!

Nama	IP	Jam Belajar	Gender
Ama	3.4	4	0
Bebi	2.7	1.5	0
Cucu	3.6	6	1
Dede	2.8	2	0
Eka	3.3	4	1
Febri	2.6	0.5	0
Gaston	3.7	6	0
Humayra	3.5	5	1
Intan	???	0	1

Lakukan estimasi parameter-parameter model, perhitungan R^2 , uji kebaikan model (uji F), signifikansi parameter model (beta untuk Jam Belajar, Gender, dan intercept), dengan menggunakan operasi vector dan matriks (bias menggunakan MS-Excel)*

*Untuk yang tidak familiar dengan operasi matriks di Excel, silakan belajar mandiri dengan memanfaatkan resources di internet (Youtube, dll)

Tugas Perhitungan Regresi Linear Majemuk dengan operasi matriks/vektor

Jika perhitungan benar, maka akan diperoleh hasil sebagai berikut (mungkin ada perbedaan di angka decimal karena pembulatan)

Model	Unstandardized Coefficients		t	Sig.
	B	Std. Error		
(Constant)	2.450	.060	40.513	.000
1 JamBel	.211	.017	12.126	.000
Gender	-.037	.070	-.530	.619

Model ^a	Sum of Squares	df	Mean Square	F	Sig.
1 Regression	1.288	2	.644	100.038	.000 ^b
Residual	.032	5	.006		
Total	1.320	7			


a. Dependent Variable: IP

b. Predictors: (Constant), Gender, JamBel

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.988 ^a	.976	.966	.08023

a. Predictors: (Constant), Gender, JamBel



BAGIAN II:

LANGKAH-LANGKAH UMUM ANALISIS REGRESI LINEAR MAJEMUK

Langkah-langkah dalam Analisis Regresi Linier Majemuk (1)

Tahap 1

Masalah Penelitian

Tentukan Tujuan :

- Prediksi
- Penjelasan

Pemilihan var. independen dan dependen

Tahap 2

Desain Penelitian

Kecukupan sampel untuk menjamin :


- Power yang memadai
- Generalisasi

Pembentukan Variabel Tambahan


- Transformasi untukenuhi asumsi
- Dummy variabel untuk nonmetric
- Polynomial untuk nonlinear
- Interaksi efek moderator


Dari Tahap 4

Langkah-langkah dalam Analisis Regresi Linier Majemuk (2)



Langkah-langkah dalam Analisis Regresi Linier Majemuk (3)






Tujuan Pemakaian Regresi Linier Majemuk

Regresi linier berganda umum digunakan untuk dua tujuan berikut:


- Prediction
- Explanation



TUJUAN (2)

Prediction


- Untuk memaksimalkan kemampuan prediksi dari variabel independen
- Untuk membandingkan dua set variabel dependen
- Prediksi seringkali dimaksimalkan dengan mengorbankan interpretasi/penjelasan
→ *time series*



TUJUAN (3)

Explanation


- Model harus didasarkan pada hubungan teoritis antara variabel dependen dan variabel-variabel independen
- Tiga perspektif dalam menginterpretasikan hasil: tingkat kepentingan variabel independen, jenis hubungan yang ditemukan dan , interrelationships di antara variabel independen



TUJUAN (4)

Statistical vs functional relationship


Sebuah hubungan fungsional menghitung nilai eksak, sebuah hubungan statistik mengestimasi nilai rata-rata dari variabel dependen.



DESAIN

Pemilihan variabel


- Pemilihan variabel harus didasarkan pada sebuah kerangka konseptual atau teoritis yang kuat
- Jika tujuan penelitian adalah eksploratoris, kita harus awas akan:
 - Kesalahan pengukuran
 - Kesalahan spesifikasi specification error
 - Mengikutkan variabel yang tidak relevan
 - Melupakan variabel yang relevan



DESAIN

Ukuran Sampel


- Ukuran sampel berpengaruh terhadap statistical power dan generalizability model
- Untuk mendapatkan tingkat generalisasi yang mencukupi, aturan umum yang berlaku adalah jumlah sampel minimum lima kali dari jumlah variabel independen (Hair, 1998)




ASUMSI-ASUMSI

- Hubungan linier
- Variansi error konstan (homoscedascity)
- Independensi error
- Error terdistribusi normal


ASUMSI: Pola error




(a) Null plot




(b) Nonlinearity




(c) Heteroscedasticity



(d) Heteroscedasticity




(e) Time-based dependence



(f) Event-based dependence


Perbaikan asumsi linieritas

(Walpole et al., 2013)



(a) Exponential function

(b) Power function




(c) Reciprocal function

(d) Hyperbolic function

Perbaiki asumsi linieritas

(Walpole et al., 2013)

Functional Form Relating y to x	Proper Transformation	Form of Simple Linear Regression
Exponential: $y = \beta_0 e^{\beta_1 x}$	$y^* = \ln y$	Regress y^* against x
Power: $y = \beta_0 x^{\beta_1}$	$y^* = \log y; \quad x^* = \log x$	Regress y^* against x^*
Reciprocal: $y = \beta_0 + \beta_1 \left(\frac{1}{x}\right)$	$x^* = \frac{1}{x}$	Regress y against x^*
Hyperbolic: $y = \frac{x}{\beta_0 + \beta_1 x}$	$y^* = \frac{1}{y}; \quad x^* = \frac{1}{x}$	Regress y^* against x^*



Penggunaan Variabel Dummy

- Setiap variabel nonmetrik dengan k kategori dapat diwakili oleh $k-1$ variabel dummy.
- Untuk k lebih dari 2, terdapat 2 cara:
 - indicator coding
 - effect coding

Contoh Penggunaan Variabel Dummy

- Untuk $k = 2$

$X_1 = 1$, jika perempuan

$X_1 = 0$, jika laki-laki


- Untuk $k = 3$, menggunakan *indicator coding*

$X_1 = 1, X_2 = 0$ jika mahasiswa S3

$X_1 = 0, X_2 = 1$ jika mahasiswa S2

$X_1 = 0, X_2 = 0$ jika mahasiswa S1

Di sini mahasiswa S1 berperan sebagai *control group*. Nilai koefisien merupakan selisih nilai variabel dependen dari grup bersangkutan terhadap grup kontrol



Interpretasi koefisien variabel dummy

- Koefisien kategori dengan variable dummy yang bernilai 1, menunjukkan selisih rata-rata kategori tersebut dibandingkan dengan kategori yang bernilai 0.
- Sebagai contoh, misalnya koefisien Gender sama dengan 0,2 artinya rata-rata IP mahasiswi (karena untuk mahasiswi Gender = 1, mahasiswa Gender = 0) lebih tinggi 0,2 dibandingkan IP rata-rata mahasiswa.

Pemodelan interaksi/moderasi


- Jika efek satu variabel independen berbeda antara satu kelompok dengan kelompok lain.
- Misalnya, efek jumlah exposure iklan lebih kuat pada perempuan dibanding pada laki-laki
- Dapat dimodelkan:

$$Y = b_0 + b_1X_1 + b_2X_2 + b_3X_1X_2$$


Di mana: b_3 adalah efek moderasi

Interpretasi koefisien term interaksi

- Dalam slide sebelumnya misalkan X_1 Jam Belajar, X_2 Gender.
- Misalnya b_3 signifikan dan bernilai +0,1, ini artinya untuk jam belajar lebih efektif 10 persen meningkatkan IP bagi mahasiswi dibandingkan bagi mahasiswa.




BAGIAN III: ESTIMASI, ANALISIS, DAN VALIDASI MODEL



ESTIMASI MODEL


- Confirmatory specification (metode enter)
- Sequential search



ESTIMASI MODEL

Confirmatory specification


- Dikenal juga sebagai metode enter
- Setiap variabel dimasukkan ke dalam model
- Kekurangan: model parsimoni



ESTIMASI MODEL

Significance of the Overall Model


- Keباikan model dalam menjelaskan atau memprediksi variabel dependen diukur dari seberapa besar variasi variabel dependen yang dapat dijelaskan oleh model (variabel-variabel independen dalam model).
- Secara statistik, signifikansi dari variasi terjelaskan oleh model (keseluruhan variable independent secara bersama-sama) ini diuji dengan uji F



ESTIMASI MODEL

Significance of the each IV

- Meskipun secara keseluruhan model signifikan, belum tentu semua variabel dalam model yang diestimasi dengan metode enter signifikan
- Signifikansi dari masing-masing variabel independen dilihat dari hasil uji t atas parameter hasil estimasi untuk masing-masing variabel
- Pada kasus ekstrim, bisa terjadi model signifikan, tetapi tidak ada satu variabel independen pun yang signifikan. Ini terjadi pada kondisi multikolinearitas tinggi



Contoh Kasus Panjang/Tinggi Bayi

Sebuah penelitian dilakukan untuk mengidentifikasi faktor apa saja yang mempengaruhi panjang bayi. Ada beberapa factor yang diperkirakan berpengaruh:

1. Usia kehamilan saat melahirkan
2. Usia ibu saat melahirkan
3. Jumlah rokok per hari dikonsumsi ibu
4. Tinggi ibu
5. Tinggi ayah

Untuk itu dikumpulkan data dari 42 bayi yang baru lahir dan data tersebut dianalisis dengan menggunakan analisis regresi linear majemuk.

Berikut hasil estimasi model menggunakan metode *confirmatory specification*

ANOVA^a

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	28.164	5	5.633	8.964	.000 ^b
	Residual	22.622	36	.628		
	Total	50.786	41			


a. Dependent Variable: Length of baby at birth (inches)

b. Predictors: (Constant), Height of father, Number of cigarettes smoked by mother (per day), Gestational age at birth (weeks), Maternal height, Age of mother

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	1.198	4.155		.288	.775
	Gestational age at birth (weeks)	.247	.049	.588	5.093	.000
	Number of cigarettes smoked by mother (per day)	-.022	.011	-.253	-2.104	.042
	Age of mother	.009	.024	.044	.362	.719
	Maternal height	.140	.052	.320	2.676	.011
	Height of father	.000	.047	.000	.004	.997


a. Dependent Variable: Length of baby at birth (inches)



Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.745 ^a	.555	.493	.793


a. Predictors: (Constant), Height of father, Number of cigarettes smoked by mother (per day), Gestational age at birth (weeks), Maternal height, Age of mother



ESTIMASI MODEL Sequential

- Tujuan: memilih sesedikit mungkin variabel independen dalam model yang memiliki kemampuan menjelaskan atau memprediksi variabel dependen semaksimal mungkin
- Variabel independen yang ada di dalam model hanya variabel independen yang signifikan
- Terdapat 2 pendekatan dalam membangun model:
 - stepwise estimation
 - forward/backward elimination

- Partial correlation: korelasi sebuah variabel independen (X_i) dan variabel dependen (Y) manakala efek dari semua variabel independen dihilangkan dari X_i dan Y



Hasil estimasi menggunakan metode stepwise

Coefficients^a

Model	Unstandardized Coefficients		Standardized Coefficients	t	Sig.
	B	Std. Error	Beta		
1 (Constant)	9.180	1.984		4.627	.000
Gestational age at birth (weeks)	.274	.051	.651	5.430	.000
2 (Constant)	2.389	3.400		.702	.487
Gestational age at birth (weeks)	.247	.049	.587	5.034	.000
Maternal height	.122	.051	.279	2.395	.022
3 (Constant)	1.430	3.282		.436	.665
Gestational age at birth (weeks)	.247	.047	.588	5.272	.000
Maternal height	.140	.049	.320	2.829	.007
Number of cigarettes smoked by mother (per day)	-.021	.010	-.238	-2.157	.037

a. Dependent Variable: Length of baby at birth (inches)

Korelasi bivariat (Pearson correlation)

Correlations

		Length of baby at birth (inches)	Gestational age at birth (weeks)	Age of mother	Number of cigarettes smoked by mother (per day)	Maternal height	Height of father
Length of baby at birth (inches)	Pearson Correlation	1	.651**	-.021	-.157	.415**	.187
	Sig. (2-tailed)		.000	.896	.320	.006	.235
	N	42	42	42	42	42	42
Gestational age at birth (weeks)	Pearson Correlation	.651**	1	.011	.043	.231	.188
	Sig. (2-tailed)	.000		.946	.786	.141	.233
	N	42	42	42	42	42	42
Age of mother	Pearson Correlation	-.021	.011	1	.340*	.047	-.204
	Sig. (2-tailed)	.896	.946		.027	.769	.196
	N	42	42	42	42	42	42
Number of cigarettes smoked by mother (per day)	Pearson Correlation	-.157	.043	.340*	1	.172	.008
	Sig. (2-tailed)	.320	.786	.027		.276	.958
	N	42	42	42	42	42	42
Maternal height	Pearson Correlation	.415**	.231	.047	.172	1	.273
	Sig. (2-tailed)	.006	.141	.769	.276		.080
	N	42	42	42	42	42	42
Height of father	Pearson Correlation	.187	.188	-.204	.008	.273	1
	Sig. (2-tailed)	.235	.233	.196	.958	.080	
	N	42	42	42	42	42	42

** . Correlation is significant at the 0.01 level (2-tailed).

* . Correlation is significant at the 0.05 level (2-tailed).

Stages dalam stepwise estimation

Excluded Variables^a

Model		Beta In	t	Sig.	Partial Correlation	Collinearity Statistics
						Tolerance
1	Number of cigarettes smoked by mother (per day)	-.186 ^b	-1.574	.124	-.244	.998
	Age of mother	-.028 ^b	-.228	.820	-.037	1.000
	Maternal height	.279 ^b	2.395	.022	.358	.947
	Height of father	.067 ^b	.545	.589	.087	.965
2	Number of cigarettes smoked by mother (per day)	-.238 ^c	-2.157	.037	-.330	.970
	Age of mother	-.040 ^c	-.350	.728	-.057	.998
	Height of father	.001 ^c	.006	.995	.001	.909
3	Age of mother	.044 ^d	.376	.709	.062	.884
	Height of father	-.009 ^d	-.082	.935	-.013	.908

a. Dependent Variable: Length of baby at birth (inches)

b. Predictors in the Model: (Constant), Gestational age at birth (weeks)

c. Predictors in the Model: (Constant), Gestational age at birth (weeks), Maternal height

d. Predictors in the Model: (Constant), Gestational age at birth (weeks), Maternal height, Number of cigarettes smoked by mother (per day)

ANOVA^a


Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	21.550	1	21.550	29.484	.000 ^b
	Residual	29.236	40	.731		
	Total	50.786	41			
2	Regression	25.297	2	12.649	19.354	.000 ^c
	Residual	25.488	39	.654		
	Total	50.786	41			
3	Regression	28.078	3	9.359	15.662	.000 ^d
	Residual	22.708	38	.598		
	Total	50.786	41			

a. Dependent Variable: Length of baby at birth (inches)

b. Predictors: (Constant), Gestational age at birth (weeks)

c. Predictors: (Constant), Gestational age at birth (weeks), Maternal height


d. Predictors: (Constant), Gestational age at birth (weeks), Maternal height, Number of cigarettes smoked by mother (per day)



INTERPRETASI

Regression vs Beta Coefficient

- Regression coefficients are sensitive to the unit of measurement (e.g: cm vs km)
- Beta coefficients are calculated based on standardized value → giving advantage when we deal with some different unit of measurement for independent variables



INTERPRETASI Efek Multikolinearitas

- The process of separating the effects of each independent variable becomes difficult
- Limits the size of the coefficient determination
- Singularity → can result in regression coefficient being incorrectly estimated

INTERPRETASI


Cara pendeteksian kolinearitas

- Matriks korelasi Pearson
- Nilai tolerance → the amount of variability of the selected independent variable not explained by the other independent variables
 - → threshold : 0,1
- Nilai Variance Inflation Factor (VIF) the degree to which each independent variable becomes a dependent variable and is regressed against the remaining independent variables.
 - → threshold : 10

Coefficients^a

Model	Unstandardized Coefficients		Standardized Coefficients	t	Sig.	Collinearity Statistics	
	B	Std. Error	Beta			Tolerance	VIF
1	(Constant)	1.198	4.155	.288	.775		
	Gestational age at birth (weeks)	.247	.049	.588	5.093	.000	.929
	Number of cigarettes smoked by mother (per day)	-.022	.011	-.253	-2.104	.042	.859
	Age of mother	.009	.024	.044	.362	.719	.839
	Maternal height	.140	.052	.320	2.676	.011	.864
	Height of father	.000	.047	.000	.004	.997	.861


a. Dependent Variable: Length of baby at birth (inches)



INTERPRETASI


Remedial bagi kolinearitas

- omit one or more highly correlated independent variables
- use the model with the highly correlated independent variables for prediction only
- use the simple correlation between independent dan dependent variable to understand the independent-dependent variable relationship
- use more sophisticated method



VALIDASI HASIL


- Validasi dapat dilakukan dengan menggunakan sampel baru (*additional sampling*) atau dengan menggunakan data yang ada
- Jika menggunakan data yang ada bisa menggunakan metode split (80% untuk estimasi: 20% untuk validasi) atau *bootstrapping*



VALIDASI

Membandingkan beberapa model

- Sebuah model (nested) dengan id. var. yang lebih banyak akan R^2 memiliki lebih besar (why?) sehingga 'tidak adil' membandingkan dua model yang jumlah id. var.-nya berbeda
- Untuk itu digunakan adjusted R^2 yang memberi penalty pada model dengan IV lebih banyak (prinsip parsimonious model)




Prediksi Menggunakan Model


- Beberapa hal yang harus diperhatikan:
 - sampel bervariasi
 - kondisi dan hubungan yang mungkin berubah seiring dengan berubahnya waktu
 - tidak menggunakan prediksi di luar range variabel independen

REGRESI LINIER MAJEMUK

(materi tambahan: analisis residual)



Mata kuliah:
MR2201 Statiska II
Minggu ke-10 & 11




ESTIMASI MODEL

Identifying Influential Observation

There are three basic types of influential observation:


- outliers: observations that have large residual values
- leverage points: observations that are distinct from the remaining observation based on their independent variable(s) value(s)
- influentials: observations that have a disproportionate effect on the regression result

Gambaran influential observation




IDENTIFYING INFLUENTIAL: Outliers (using residuals)

- Outliers do not have to be influential observation and vice versa
- We can point an outlier using residuals:
 1. (normal) residual : $Y_i - \hat{Y}_i$
 2. Standardized residual: residual / Stdev of residual
 3. Deleted residual: $Y_i - \hat{Y}_i^{(i)}$
where $\hat{Y}_i^{(i)}$ indicates the predicted value when i^{th} case is excluded
 4. Studentized residual: similar to standardized residual except the denominator is standard deviation of residual *when i^{th} case is excluded*




IDENTIFYING INFLUENTIAL: Outliers (using residuals)

5. Studentized deleted residual: similar to studentized residual except the nominator is deleted residual



IDENTIFYING INFLUENTIAL: Outliers (using partial regression plot)


- Partial regression plot is constructed by plotting the values of *each* independent variable vs dependent variable.



IDENTIFYING INFLUENTIAL: Leverage (Hat matrix)


$$\hat{Y} = HY$$

- Di sini matriks H disebut dengan *hat matrix* dan diagonalnya disebut dengan *hat values*
- *Hat value* membawa dua informasi:
 - ukuran jarak dari observasi tersebut terhadap pusat (mean center) dari seluruh observasi atas seluruh variabel independen yang ada (mirip dengan jarak Mahalanobis)
 - hat value yang besar menunjukkan bobot yang tidak proporsional dalam menentukan nilai variabel dependen yang diprediksi
- Nilai hat value dianggap besar jika $> 2p/n$ (p jumlah variabel independen dan n jumlah observasi) untuk sampel besar dan $> 3p/n$ untuk sampel kecil



IDENTIFYING INFLUENTIAL: Leverage (Mahalanobis Distance)

- Influential observation dapat diidentifikasi jika jarak Mahalanobis terbesar dua atau tiga kali dari jarak Mahalanobis terbesar kedua (dan seterusnya)




IDENTIFYING INFLUENTIAL: Influentials (DFBETA & SDFBETA)

- DFBETA: impact of deleting a single observation on each regression coefficient
- SDFBETA: standardized version of DFBETA
- DFBETA is the relative effect of an observation on each coefficient
- Guidelines for identifying high value SDFBETA
 - ± 1 or ± 2 for small sample sizes
 - $\pm 2\sqrt{n}$ for medium and larger sample sizes

IDENTIFYING INFLUENTIAL: Influentials (Cook' s Distance)


- Cook' s distance measures the impact of an observation from two sources:
 - the size of changes in the predicted values when the case is omitted
 - observation' s distance from other observations

$$C_i = \frac{\sum_{j=1}^n \left(\hat{Y}_j^{(i)} - \hat{Y}_j \right)^2}{(p+1)S^2}$$




IDENTIFYING INFLUENTIAL: Influentials (Cook's Distance)

- Rule of thumb to point influentials:
 - Cook's distance $> 4 / (n - p - 1)$
 - Cook's distance > 1 (for greater sample sizes)



IDENTIFYING INFLUENTIAL: Influentials (COVRATIO)

- COVRATIO represents the degree to which an observation impacts the standard errors of the regression coefficients
- The threshold are $1 \pm 3p/n$



IDENTIFYING INFLUENTIAL: Influentials (SDFFIT)

- SDFFIT measures the degree to which the fitted values change when the case is deleted
- The cutoff value : $2\sqrt{(k+1)/(n-k-1)}$