Additional Material Cluster Analysis

K-means



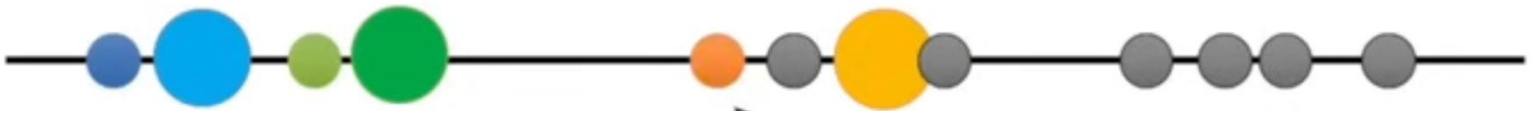
Step 1:

- pilih k centroid randomly



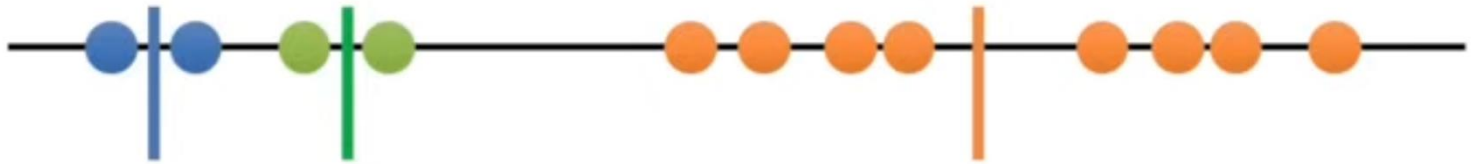
Step 2

- Tentukan keanggotaan semua titik ke centroid terdekat



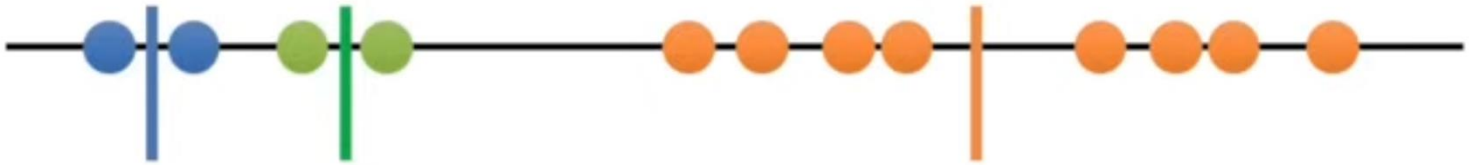
Step 3

- Hitung centroid baru dari seluruh titik anggota cluster



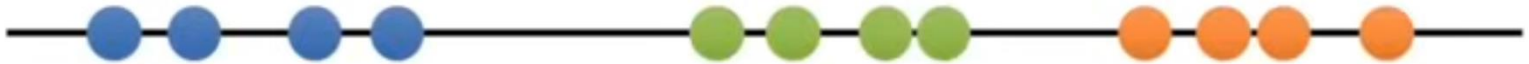
Step 4

- Hitung jarak dari setiap titik ke centroid baru
- Kelompokkan titik (re-assign) ke klaster baru berdasarkan jarak ke centroid klaster terdekat



Step 5

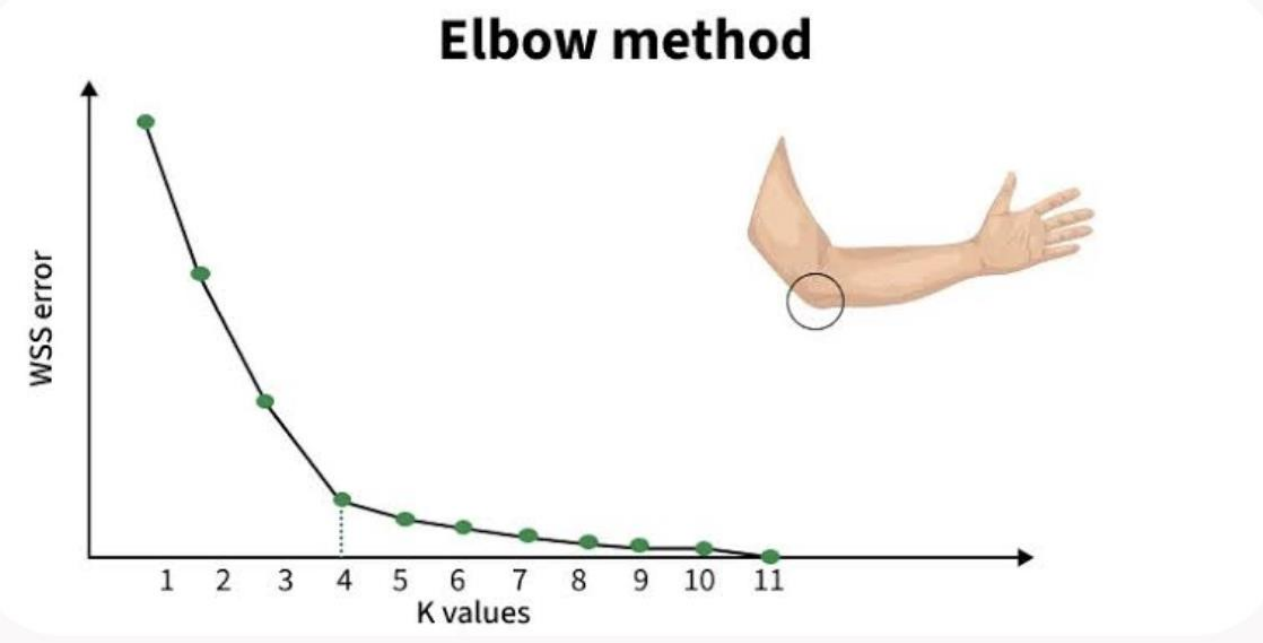
- Jika solusi sudah tidak berubah (tidak ada perubahan nilai centroid) maka solusi sudah final



Memilih k-terbaik

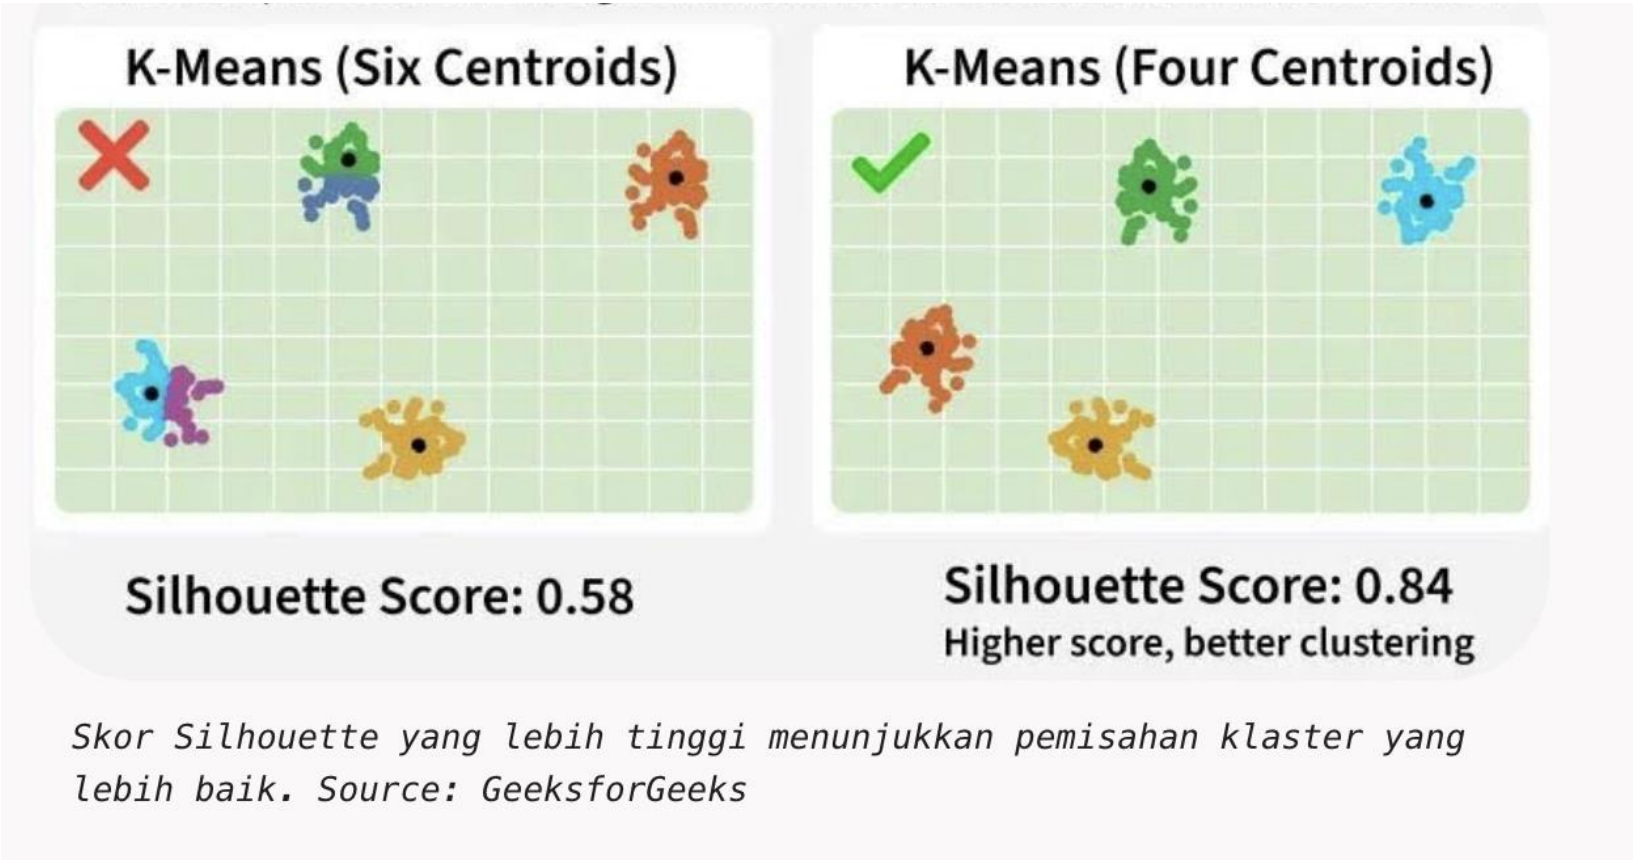
- Ulangi untuk beberapa k
- Gunakan metode elbow atau silhoutte untuk memilih k terbaik

Elbow method



- Y-axis is within cluster sum-of-squares (distance of each point to the cluster's centroid)
- The 'optimal' k is the position of the elbow

Silhoutte score - method



Skor Silhouette yang lebih tinggi menunjukkan pemisahan klaster yang lebih baik. Source: GeeksforGeeks

Skor silhoutte

$$S = \frac{b - a}{\max(a, b)}$$

1. **Kohesi (a):** Jarak rata-rata antara titik tersebut dengan semua titik lain di dalam *klaster yang sama*. Semakin kecil nilai a, semakin baik (berarti data mengelompok dengan rapat).
2. **Pemisahan (b):** Jarak rata-rata antara titik tersebut dengan semua titik di *klaster tetangga terdekat* (klaster lain yang posisinya paling dekat). Semakin besar nilai b, semakin baik (berarti klaster terpisah jauh dari klaster lain).

Semakin besar skor silhoutte, semakin baik.