

Segmentasi Pelanggan Accor Indonesia dengan Analisis Cluster

TI5102 Analisis Data dan Statistik

Kelompok 5

Bonifasius Argyanto (23426002)

Aulya Az Zaafirrahman (23426014)

Gibran Juniansyah (23426702)

M Aqilla Khalafazka S (23426709)

Luthfi Nur Muharram (23426711)



Latar Belakang, Tujuan dan Data

Latar Belakang

Accor mengelola hotel dari kelas luxury hingga economy di Indonesia lewat program loyalty ALL (Accor Live Limitless). Selama ini semua member menerima penawaran yang sama, sehingga respon terhadap kampanye terus menurun dan pemesanan lewat OTA (Online Travel Agent) justru meningkat.

Manajemen membutuhkan segmentasi member berdasarkan perilaku menginap dan belanja sepanjang 2025, serta rekomendasi segmen mana yang perlu diprioritaskan mengingat keterbatasan anggaran.

Variabel demografi dan sosial-ekonomi tidak digunakan untuk membentuk klaster, melainkan hanya untuk memprofilkan dan memberi nama pada segmen.

Tujuan Analisis

- Memilih variabel perilaku yang tidak redundan.
- Membentuk segmen: Metode Ward pada Dataset A1, lalu K-Means pada Dataset A2.
- Menguji konsistensi dan stabilitas hasil klaster.
- Memprofilkan segmen dengan uji statistik.
- Menamai, menentukan prioritas, dan merancang program pemasaran.

Data

Menggunakan data 2.000 member ALL (1 Jan – 31 Des 2025) yang dibagi secara acak: A1 = 1.000 (Hierarkis) dan A2 = 1.000 (K-Means).

Terdiri dari 16 variabel perilaku dari PMS, POS, dan aplikasi ALL, serta 8 variabel demografi dan sosial-ekonomi (kondisi data mentah, belum dibersihkan).

Alur Analisis dan Pilihan Teknis

Tahap	Pilihan	Justifikasi
Software	Python (Jupyter): scipy, scikit-learn, statsmodels, dan fungsi custom tambahan	Terdokumentasi dan dapat direplikasi secara konsisten.
Pembersihan	Aturan logika bisnis + uji identitas akuntansi	Mencegah outlier dan data placeholder membentuk kluster kecil yang tidak valid (1–3 orang).
Persiapan variabel	Transformasi log1p (skewness > 1), z-score, serta seleksi via korelasi & VIF	Mengendalikan nilai ekstrem dan menghilangkan redundansi antarvariabel.
Hierarkis (A1)	Jarak Euclidean & linkage Ward	Meminimalkan varians di dalam kluster serta menghindari efek chaining.
Jumlah cluster	Agglomeration schedule, Silhouette, Calinski-Harabasz, Davies-Bouldin, Elbow, dan pertimbangan bisnis	Memastikan keputusan jumlah kluster didukung oleh bukti statistik dan alasan bisnis.
K-means (A2)	Nilai k dari metode hierarkis, k-means++, n_init = 30	Melakukan replikasi independen menggunakan algoritma yang berbeda.
Validasi dan profiling	ARI (Adjusted Rand Index), penempatan silang, bootstrap; ANOVA, Kruskal-Wallis, Chi-square (Bonferroni)	Menguji stabilitas kluster serta mengidentifikasi variabel pembeda antar-segmen.

Prinsip Utama

Setiap keputusan ditetapkan secara eksplisit dan didasarkan pada data. Keputusan berbasis penilaian subjektif (seperti batas anomali atau bobot daya tarik) dinyatakan secara terbuka sebagai asumsi dan diuji sensitivitasnya.

n = 2.000, 16 variabel perilaku

Pembersihan Data

17

baris anomali deliminasi
(9 A1 + 8 A2)

991 | 992

member bersih A1 | A2

0 missing

namun ditemukan nilai yang
tidak logis

Aturan anomali	Alasan bisnis	A1	A2
lead_time = 999	Kode placeholder PMS	1	1
total_nights > 365	Tidak memungkinkan dalam 1 tahun	0	1
avg_los > 30 malam	Luar pola hotel reguler (kasus batas)	3	3
spa per stay > Rp1 miliar	Terindikasi kesalahan satuan	1	0
ADR > Rp100 juta	Tidak realistis	1	1
ADR < Rp100 ribu	Di bawah tarif terendah Accor	2	3
family_facility > 20	Tidak wajar per kedatangan	1	0
Baris unik dibuang	Satu baris dapat melanggar >1 aturan	9	8


Uji Identitas Akuntansi

- room_spend dan total_spend merupakan nilai turunan (100% data konsisten ±1%)
- points_earned = 0,0001 × total_spend (1 poin per Rp10.000)
- total_nights ≈ stays × avg_los (95% data berada dalam toleransi ±15%)

Ekstrem tetapi valid

6 member (>52 stay/tahun atau ADR Rp15–100 juta) dipertahankan karena konsisten secara akuntansi dan ditangani melalui transformasi log.

Transformasi Log: Sebelum dan Sesudah



Hasil

- 12 dari 16 variabel memiliki kemiringan distribusi tinggi (skewness 1,35–12,69), sehingga ditransformasi menggunakan log1p
- Penurunan skewness secara signifikan: adr 10,07 → 0,38
spa_per_stay 12,69 → 0,39
stays_per_year 9,82 → 0,86
- family_facility (1,35) dan business_facility (1,21) masih cenderung miring karena didominasi nilai mendekati nol
- Beberapa variabel menunjukkan distribusi bimodal setelah transformasi log, mengindikasikan pemisahan awal antara kelompok reguler dan premium
- Setelah transformasi log, seluruh variabel distandarisasi menggunakan z-score.

Seleksi Variabel Pembentuk Cluster

Kelompok Redundan	Keputusan	Dasar
total_spend, room_spend, points_earned	Dieliminasi semua	r 0,99–1,00 VIF 921–1.599
total_nights	Dieliminasi	= stays × avg_lo VIF 550
ota_pct vs direct_pct	Pertahankan ota_pct	r = −0,99 fokus utama pada isu OTA
app_sessions	Dieliminasi	r = 0,90 dengan variabel kanal
spa vs fnb_per_stay	Pertahankan fnb_per_stay	r = 0,88

9 variabel final

stays_per_year, avg_lo, adr, fnb_per_stay, weekday_pct, lead_time, ota_pct, family_facility, business_facility

7 variabel ditransformasi log (kecuali weekday_pct dan ota_pct), kemudian distandardisasi dengan z-score. Pemilihan satu variabel dari pasangan yang berkorelasi tinggi didasarkan pada relevansi bisnis.

16 → 9

variabel pembentuk cluster

1.599 → 5,5


VIF maksimum (sebelum dan sesudah)

0,81

korelasi maksimum tersisa
(relevan secara bisnis)

Klaster Hierarkis: Metode Aglomerasi




Metode	Cophenetic	Silhouette	Ukuran Klaster (k = 4)
Single	0,861	0,178	983 / 3 / 3 / 2
Average	0,883	0,279	982 / 3 / 3 / 3
Complete	0,810	0,497	296 / 296 / 249 / 150
Ward	0,836	0,497	296 / 296 / 249 / 150



Alasan Pemilihan Ward

- Single & Average linkage mengalami gejala chaining (membentuk 1 kluster raksasa dan kluster-kluster kecil berisi 2–3 anggota)
- Complete linkage menghasilkan performa setara dengan Ward pada data ini, namun Ward meminimalkan varians di dalam kluster (sejalan dengan tujuan K-Means)
- Nilai Cophenetic tertinggi (Average) tidak menjamin hasil yang intuitif secara bisnis; evaluasi harus mempertimbangkan distribusi ukuran kluster dan skor Silhouette secara bersamaan.

Menentukan Jumlah Kluster: $k = 4$



k	Silhouette	Calinski-H.	Davies-B.	Lonjakan biaya
3	0,509	1.131	0,739	+89%
4	0,497	1.118	0,852	+184%
5	0,361	885	1,499	+3%
6	0,294	746	1,869	+14%

Keputusan: 4 cluster

- Biaya penggabungan melonjak $\pm 184\%$ dari $k=4$ ke $k=3$, sementara seluruh indeks validasi mengalami penurunan signifikan setelah $k=4$
- Meskipun $k=3$ memiliki nilai statistik sedikit lebih tinggi, opsi tersebut menggabungkan kelompok 249+150 member yang tarif dan kanal pemesanannya berbeda jauh (ADR Rp1,34 vs Rp3,76 juta, OTA 39% vs 12%, profil lengkap di slide 12-14)

K-means pada Dataset A2

k = 4

dari hierarkis,
mereplikasi pola A1

2.087,5

WSS final (inertia)

30

titik awal percobaan
(k-means++, random_state 42)

150/248/297/297

ukuran klaster A2

	Titik awal acak murni	Titik awal kmeans++
Mencapai WSS terbaik (dari 30 percobaan)	16	24
WSS terbaik	2.087,5	2.087,5
WSS terburuk	4.355,5	2.704,1


WSS = jumlah kuadrat jarak setiap member ke centroid klasternya. WSS 2.087,5 ≈ 23,4% dari total variasi (≈ 8.928), artinya 4 cluster mampu menjelaskan ±76,6% variansi data.

Mekanisme: inisialisasi k centroid awal → alokasikan setiap member ke centroid terdekat → perbarui posisi centroid ke rata-rata anggota → iterasi hingga konvergen (tidak ada perubahan alokasi)

Jebakan Local Optimum

- Titik awal acak murni: hanya 16 dari 30 percobaan yang mencapai solusi optimal
- Beberapa iterasi terjebak di WSS 4.355 (dua kali lebih buruk dari nilai optimal)
- Penggunaan k-means++ meningkatkan tingkat keberhasilan menjadi 24 dari 30 percobaan. Oleh karena itu, ditetapkan titik awal = 30 percobaan.

Konsistensi A1 (Ward) vs A2 (K-Means)



ARI = 1,00

penempatan silang A2 ke centroid A1

100%

kesesuaian penempatan 992 member A2

0,06 SD

selisih centroid maksimum (rata-rata 0,02 SD)

1,000

ARI bootstrap
(100 resample 80% data, nilai min = maks)

Klaster	A1 Ward	A2 K-means	Selisih Anggota
0	150 (15,1%)	150 (15,1%)	0
1	249 (25,1%)	248 (25,0%)	1
2	296 (29,9%)	297 (29,9%)	1
3	296 (29,9%)	297 (29,9%)	1

Jjarak centroid klaster pasangan sejenis (A1 vs A2) hanya 0,05–0,09 SD, sedangkan jarak antar-segmen berbeda mencapai 2,7–5,5 SD (sekitar ≥ 30 kali lebih jauh).

Dampak Respesifikasi dan Persiapan Data

Spesifikasi	Ukuran kluster A1	Silhouette	ARI A1↔A2
1. Data mentah, 16 var, tanpa log	691 / 298 / 10 / 1	0,381	0,698
2. Dengan pembersihan data	399 / 296 / 293 / 3	0,418	0,991
3. Dengan Transofrmasi log (16 var)	296 / 296 / 249 / 150	0,479	1,000
4. Final: 9 var, data bersih, + log	296 / 296 / 249 / 150	0,497	1,000

0,698 → 1,000

Peningkatan ARI
setelah respesifikasi


Temuan Utama

- Spesifikasi 1 gagal: Dua segmen terisolasi hanya berisi 10 dan 1 anggota akibat efek outlier.
- Konsisten belum tentu ideal: Spesifikasi 2 sangat konsisten (ARI 0,991), namun masih memiliki kluster sangat kecil (3 anggota)
- Pembersihan data dan transformasi log memberikan dampak paling signifikan, sedangkan seleksi variabel mengoptimalkan keterbacaan profil

Uji Nilai k Lain (Spesifikasi Final)

- k = 3 dan k = 4: Menghasilkan ARI sempurna (1,00)
- k = 5: Nilai ARI turun menjadi 0,787; kluster kelima tidak stabil/konsisten (A1 dan A2 terpecah pada titik yang berbeda)
- Mengeliminasi k >= 5, pemilihan antara k = 3 vs k = 4 didasarkan pada pertimbangan analisis di Langkah 3

Profil Perilaku Segmen



Rata-rata	Klaster 3	Klaster 0	Klaster 1	Klaster 2
Stay / tahun	14,4	4,4	2,6	3,2
Rata-rata menginap (malam)	1,9	2,9	3,6	1,7
ADR (Rp juta)	1,52	3,74	1,35	0,63
F&B per stay (Rp ribu)	273	2.376	1.504	158
Malam hari kerja (%)	85	41	25	50
Lead time (hari)	7,6	30,8	48,9	15,4
OTA (%)	10	12	40	76
Sesi aplikasi / bulan	8,1	7,8	5,3	2,2

Uji Signifikansi Perilaku (ANOVA, Kruskal-Wallis, Bonferroni)

- Seluruh 16 variabel signifikan membedakan segmen ($p < 0,001$, $\eta^2 \geq 0,14$). Pembeda terkuat meliputi ota_pct (η^2 0,83), direct_pct (0,81), weekday_pct (0,76), dan app_sessions (0,64)
- Tidak ada variabel tunggal yang memisahkan keempat segmen secara instan. Segmen terbentuk dari kombinasi banyak dimensi
- Uji signifikansi pada 9 variabel pembentuk klaster bersifat inheren. Bukti pembeda yang independen ditunjukkan oleh variabel yang tidak dipakai dalam clustering (seperti app_sessions, direct_pct, total_spend) serta data demografi

Profil Demografi dan Uji Statistik

Profil	Klaster 3	Klaster 0	Klaster 1	Klaster 2
Usia rata-rata (tahun)	37,8	50,2	41,5	28,2
Rata-rata anak < 12 tahun	0,32	0,32	1,93	0,07
Menikah (%)	56	80	97	24
Penghasilan > Rp50 jt (%)	15	62	15	3
Penghasilan < Rp25 jt (%)	43	7	49	89
Pekerjaan dominan	Manajer (64%)	Eksekutif (42%)	Manajer (39%)	Karyawan Junior (49%)

Validasi Eksternal

Meskipun data demografi tidak digunakan dalam pembentukan klaster, variabel usia, jumlah anak, status pernikahan, pekerjaan, dan pendapatan menunjukkan perbedaan signifikan antar-segmen. Hal tersebut membuktikan bahwa segmen perilaku merefleksikan kelompok populasi yang riil, bukan sekadar kebetulan algoritma.

Variabel	Uji	Effect size	Signifikan Membedakan
age	ANOVA	η^2 0,684	Ya
num_children	ANOVA	η^2 0,540	Ya
marital_status	χ^2	V 0,575	Ya
occupation	χ^2	V 0,435	Ya
monthly_income	χ^2	V 0,412	Ya
domicile	χ^2	V 0,030	Tidak
gender	χ^2	V 0,028	Tidak
education	χ^2	V 0,020	Tidak

Variabel gender, pendidikan, dan domisili tidak membedakan segmen secara signifikan ($p > 0,6$) sehingga tidak informatif untuk digunakan sebagai dasar penargetan.

Penamaan Segmen

SIBUK

30% member. **Klaster 3**

Sering inap untuk bisnis dan urusan kerja

- 14,4 stay/tahun
- 85% malam hari kerja (weekday)
- Penggunaan fasilitas bisnis tertinggi
- Usia rata-rata 38 tahun, (64% manajer/profesional)

MAPAN

15% member. **Klaster 0**

Menikmati akomodasi premium, anggaran aman

- ADR tertinggi: Rp3,74 juta
- Belanja F&B Rp2,38 juta per stay
- 62% berpenghasilan > Rp50 juta
- Usia rata-rata 50 tahun, (74% eksekutif/pengusaha)

RAMEAN

25% member. **Klaster 1**

Rencana lebih awal, menginap ekstra lama bersama anak

- Lead time panjang (49 hari)
- Durasi menginap terlama (3,6 malam)
- Rata-rata 1,93 anak < 12 tahun
- 97% berstatus menikah

CERMAT

30% member. **Klaster 2**



Cari ekonomis, reservasi mayoritas lewat agen travel

- ADR terendah (Rp0,63 juta)
- 76% pemesanan melalui OTA
- Usia rata-rata 28 tahun, (76% lajang)
- 89% berpenghasilan < Rp25 jt

Disclaimer: Penamaan segmen bersifat interpretatif berdasarkan pola perilaku dan profil dominan, bukan variabel yang diukur secara langsung dalam sistem.

Daya Tarik Segmen

Segmen	% member	% belanja	Ukuran	Nilai	Akses	Skor	Rank	Sensitivitas Bobot
SIBUK	29,9	45,4	5,00	3,48	5,00	4,39	1	Peringkat #1 pada 4 dari 5 skema
MAPAN	15,1	35,8	1,00	5,00	4,84	3,75	2	Peringkat #1 jika fokus ke nilai
RAMEAN	25,1	14,8	3,69	1,82	3,14	2,78	3	Konsisten peringkat #3 seluruh skema
CERMAT	29,9	4,0	5,00	1,00	1,00	2,20	4	Peringkat #4 pada mayoritas skema



Kriteria Pembobotan

- Ukuran (30%): Proporsi jumlah member
- Nilai (40%): Rata-rata total belanja
- Kemudahan Akses (30%): Tingkat direct booking & aktivitas aplikasi
- Skor menggunakan skala min-max 1-5, asumsi pembobotan telah diuji sensitivitasnya pada 5 skema berbeda

Segmen Prioritas dan Usulan Program

	SIBUK (prioritas 1)	MAPAN (prioritas 2)
Sasaran	Meningkatkan frekuensi menginap dan retensi, serta mempertahankan porsi direct booking	Naikkan frekuensi menginap dan belanja spa/F&B
Dasar data	14 stay/tahun, 85% hari kerja, 83% booking langsung, lead time 7 hari	Rata-rata 4 stay/tahun, ADR Rp3,7 juta, F&B Rp2,4 juta dan spa Rp1,5 juta per stay
Penawaran	Express check-in/late check-out, bonus poin stay hari kerja berturut-turut, upgrade otomatis di menginap ke-N, tarif khusus korporat di aplikasi	Paket weekend escape (spa + dining), akses pengalaman eksklusif, tukar poin ke upgrade suite
Kanal dan waktu	Aplikasi dan notifikasi, dikirim awal pekan (sesuai lead time yang singkat)	Kanal personal (concierge/email), dikirim 3–4 minggu sebelum long weekend
KPI	Stay per member, retensi, share booking langsung	Stay per member, belanja spa/F&B per stay, ADR

RAMEAN (opsional): Paket keluarga eksklusif via website/aplikasi ALL (dikirim 6–8 minggu sebelum libur sekolah). KPI Utama: penurunan porsi pemesanan via OTA (target <40%).

CERMAT: Cukup dijaga dengan komunikasi otomatis berbiaya rendah (low-cost retention). Uji coba program skala kecil perlu dilakukan sebelum resmi diluncurkan.

Empat Segmen, Dua Prioritas

4

segmen konsisten dan stabil
(ARI = 1,00)

9

variabel pembentuk kluster
(seleksi dari 16)

81%

total belanja didominasi
SIBUK + MAPAN (45% populasi)

17

data anomali dieliminasi

Analisis kluster terhadap 2.000 member ALL berhasil mengidentifikasi empat segmen yang sangat konsisten pada dua sampel dan dua algoritma berbeda: SIBUK (perjalanan dinas), MAPAN (customer premium), RAMEAN (keluarga liburan), dan CERMAT (pelanggan sensitif harga). Tahapan pembersihan data, transformasi log, dan seleksi variabel menjadi kunci utama kestabilan model (spesifikasi mentah terbukti gagal karena menghasilkan kluster terisolasi berisi 1 dan 10 anggota).

Rekomendasi Strategis: Prioritaskan alokasi anggaran pada segmen SIBUK (fokus pada retensi dan frekuensi) serta MAPAN (fokus pada frekuensi dan belanja penunjang F&B/Spa). Kelola segmen RAMEAN secara efisien untuk menekan porsi pemesanan via OTA, serta pertahankan segmen CERMAT dengan komunikasi otomatis berbiaya rendah.

Keterbatasan & Asumsi: Batas anomali dan bobot daya tarik bersifat asumsi, nilai segmen diukur berdasarkan pendapatan (bukan laba bersih), penamaan segmen merupakan interpretasi, usulan program memerlukan uji coba sebelum resmi diluncurkan.