Kerangka Desain Eksperimen

Pengaruh Sumber Pre-training, Ukuran Patch, dan Jumlah Data Latih terhadap Akurasi Klasifikasi Mutu Biji Kopi Arabika Berbasis Vision Transformer (ViT)

Mata kuliah Desain Eksperimen — Analisis Data & Statistik. Data: skripsi Aulya Az Zaafirrahman (Teknologi Industri Pertanian, Universitas Brawijaya), citra biji kopi arabika dengan label mutu SNI 01-2907-2008.

Ringkasan (siap untuk template poin 1 dan 2)

- **Topik.** Desain eksperimen faktorial untuk menguji pengaruh sumber pre-training, ukuran patch, dan jumlah data latih terhadap akurasi klasifikasi mutu biji kopi arabika dengan ViT.
- **Tujuan.** Mengetahui faktor dan interaksi yang berpengaruh nyata terhadap akurasi ($\alpha = 0{,}05$), lalu menentukan konfigurasi terbaik. Hipotesis nol: tidak ada efek utama maupun interaksi.
- **Respon.** Akurasi klasifikasi pada test set (240 citra dari 24 sampel fisik yang tidak ikut training), dihitung dari confusion matrix oleh satu skrip evaluasi dengan seed tercatat.
- **Faktor.** A: sumber pre-training (ImageNet, HuggingFace) · B: patch size (16, 32) · C: jumlah data latih (16/14/10/8 sampel per kelas).
- **Rancangan.** Faktorial 2×2×4 dalam Rancangan Acak Kelompok, 10 blok → 16 perlakuan × 10 = 160 run. Analisis: ANOVA tiga arah dengan blok, uji asumsi, Tukey HSD.

1. Tujuan dan Rumusan Masalah

Sortasi biji kopi arabika berdasarkan sistem nilai cacat (mutu 1–6, SNI 01-2907-2008) umumnya dilakukan dengan pemeriksaan visual oleh operator, yang subjektif dan memakan waktu. Skripsi sumber data membangun klasifikasi mutu berbasis citra dengan Vision Transformer (ViT) transfer learning, tetapi setiap konfigurasi hanya dijalankan **satu kali**. Tanpa replikasi tidak ada estimasi galat percobaan, sehingga perbedaan akurasi antar konfigurasi tidak dapat diuji secara statistik. Eksperimen ini menutup celah tersebut.

Tujuan

- Menguji pengaruh sumber pre-training (A), ukuran patch (B), dan jumlah data latih (C) terhadap akurasi.
- Menguji ada tidaknya interaksi antar faktor (AB, AC, BC, ABC).
- Menentukan konfigurasi terbaik melalui perbandingan berpasangan (Tukey HSD) bila ada efek nyata.

Rumusan masalah

- Apakah sumber pre-training, ukuran patch, atau jumlah data latih berpengaruh nyata terhadap akurasi klasifikasi mutu?
- Apakah pengaruh satu faktor bergantung pada level faktor lain (misalnya pengaruh jumlah data latih berbeda antara patch 16 dan patch 32)?
- Konfigurasi mana yang menghasilkan akurasi tertinggi, dan apakah berbeda nyata dari konfigurasi lain?

Hipotesis ($\alpha = 0{,}05$)

Efek	H_0	H_1
A, B, C (efek utama)	Rata-rata akurasi sama di semua level faktor tersebut	Minimal satu level berbeda
AB, AC, BC (interaksi dua arah)	Pengaruh suatu faktor sama di semua level faktor lain	Pengaruhnya berubah menurut level faktor lain
ABC (interaksi tiga arah)	Pola interaksi dua arah sama di semua level faktor ketiga	Pola interaksi berbeda
Blok (replikasi)	Tidak ada perbedaan antar blok (dipakai untuk mengurangi galat, bukan hipotesis utama)	—

Dugaan awal dari skripsi: patch 16 cenderung lebih akurat daripada patch 32 pada semua konfigurasi yang dijalankan, dan data latih yang lebih banyak cenderung membantu. Peran sumber pre-training belum jelas, dan mungkin bergantung pada patch size.

2. Variabel Respon

Respon	Definisi dan cara ukur	Peran
Akurasi test (*test_acc*)	Jumlah citra test yang diprediksi benar ÷ 240, dihitung dari prediksi argmax model pada **epoch terakhir**. Test set berisi 4 sampel fisik per kelas (24 sampel, 240 citra), identik untuk semua perlakuan dalam satu blok.	Respon utama (dianalisis ANOVA)
Akurasi set prediksi (*pred_acc*)	Akurasi pada 60 citra prediksi eksternal (10 per kelas, nama file P1A–P1J dst.), yang tidak termasuk 1200 citra training/testing.	Respon sekunder (analisis terpisah)
Macro-F1 test	Rata-rata F1 enam kelas pada test set yang sama.	Pelengkap, tidak diuji formal
Loss akhir dan *loss_drop_last10*	Loss training epoch terakhir dan penurunan relatifnya sejak 10 epoch sebelumnya (≈ 0 berarti konvergen).	Diagnostik konvergensi, bukan respon

Keakuratan dan konsistensi alat ukur. Evaluasi dilakukan oleh satu skrip yang sama untuk semua run; fitur dari backbone bersifat deterministik (tanpa augmentasi acak, dropout backbone = 0); seed setiap run dicatat; model yang dievaluasi selalu bobot epoch terakhir sehingga test set tidak ikut memilih model. Resolusi respon utama 1/240 ≈ 0,42 poin persen, lebih halus daripada set prediksi skripsi (1/60 ≈ 1,67 poin).

3. Faktor, Level, dan Rentang

Faktor	Level	Keterangan
A. Sumber pre-training	2: ImageNet (torchvision), HuggingFace	ImageNet: ViT_B_16/32 Weights.DEFAULT, input 224 px. HuggingFace: google/vit-base-patch16-224 (224 px) dan google/vit-base-patch32-384 (384 px).
B. Ukuran patch	2: 16×16 px, 32×32 px	Sama dengan skripsi.
C. Jumlah data latih	4: 16, 14, 10, 8 sampel fisik per kelas	Setara 80/70/50/40% dari 20 sampel per kelas, yaitu 960/840/600/480 citra. Rentang mengikuti skripsi (80:20 sampai 40:60), tetapi test set dikunci.

Faktor yang dikontrol (tetap untuk semua perlakuan)

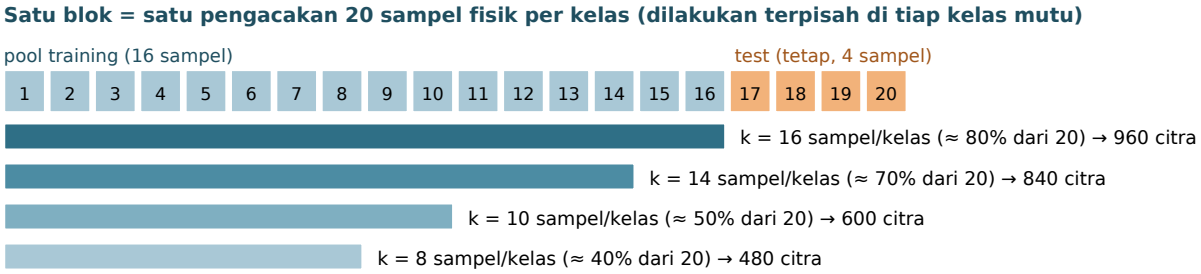
Aspek	Nilai tetap
Arsitektur	ViT-Base dengan backbone beku (frozen); hanya head yang dilatih: Dropout(0,1) + Linear 768→6 (4.614 parameter).
Training head	AdamW, learning rate 1e-3, weight decay 0,03, batch 10, **90 epoch**, CrossEntropyLoss. Identik untuk semua perlakuan, termasuk HuggingFace (di skripsi HF memakai 50 epoch, lr 1e-4, tanpa dropout head).
Preprocessing	Deterministik: transform resmi tiap model, tanpa augmentasi acak (flip acak pada notebook HF lama dibuang).
Akuisisi citra	Box CHIGAR 30×30×30 cm, kamera Redmi Note 10S, jarak 15 cm, area 6×6 cm, ISO 200, shutter 1/10, alas kertas HVS putih.
Bahan	Biji kopi arabika dari satu pemasok (UMKM Sarie Kopi, kebun Gunung Ijen), 10 g per sampel, setiap foto dengan posisi biji diacak ulang.
Komposisi data	Seimbang: 6 mutu × 20 sampel × 10 foto = 1200 citra.

Faktor pengganggu yang diblok: komposisi sampel pada split train/test (sebagian sampel bisa lebih mudah atau lebih sulit). **Catatan pencampuran (confounding):** pada patch 32, level HuggingFace memakai resolusi 384 px sedangkan ImageNet 224 px, sehingga efek sumber di patch 32 tercampur dengan efek resolusi.

4. Unit Eksperimen, Ukuran Sampel, dan Tiga Prinsip Dasar

Unit eksperimen adalah satu kali run training head (satu perlakuan dalam satu blok dengan satu seed), **bukan** satu citra. Total 16 perlakuan × 10 blok = **160 run**.

Level C (sampel/kelas)	Sampel train	Citra train	Sampel test	Citra test
16	96	960	24	240
14	84	840	24	240
10	60	600	24	240
8	48	480	24	240



Train set bersifat bersarang (8 sampel pertama termasuk di 10, 14, dan 16) sehingga perbedaan antar level C hanya berasal dari jumlah data, bukan dari sampel yang berbeda.

Jumlah replikasi. Dipilih 10 blok secara pragmatis: murah karena hanya head yang dilatih ulang, dan memberi derajat bebas galat 135 (lihat Bagian 5). Belum ada perhitungan daya uji formal; bila diminta, dapat ditambahkan dari simpangan baku antar blok pada run percontohan.

Prinsip	Penerapan
Replikasi	Tiap kombinasi perlakuan diulang di 10 blok dengan seed berbeda, sehingga galat percobaan dapat diestimasi dan ANOVA valid.
Randomisasi	Alokasi sampel fisik ke train/test diacak per kelas pada tiap blok (seed = 2024 + nomor blok); urutan 16 perlakuan dalam blok diacak dan dicatat (*run_order*).
Blocking	Blok = replikasi. Seluruh perlakuan dalam satu blok memakai test set dan pool train yang sama, sehingga variasi tingkat kesulitan split tidak mengotori perbandingan antar perlakuan.

Split dilakukan di level **sampel fisik**, bukan per citra. Sepuluh foto satu sampel memuat biji yang sama; bila dipecah per citra, biji yang sama bisa muncul di train dan test sehingga akurasi terlalu optimis.

5. Rancangan yang Dipilih

Faktorial 2×2×4 dalam Rancangan Acak Kelompok (RAK/RBD). Semua faktor bertipe kategorik sehingga RSM dan Taguchi kurang cocok. Faktorial penuh dipilih agar seluruh interaksi dapat diuji. Pengacakan sampel ke train/test menjadi dasar pengelompokan, karena tiap blok adalah satu hasil pengacakan.

Model: $Y_{ijkm} = \mu + \rho_m + \alpha_i + \beta_j + \gamma_k + (\alpha\beta)_{ij} + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk} + (\alpha\beta\gamma)_{ijk} + \varepsilon_{ijkm}$, dengan ρ blok, α sumber, β patch, γ jumlah data latih.

Sumber keragaman	db	Sumber keragaman	db
Blok	9	A×C	3
A (sumber)	1	B×C	3
B (patch)	1	A×B×C	3
C (jumlah data)	3	Galat	135 = 9×15
A×B	1	Total	159

Blok diperlakukan sebagai efek tetap, seperti RAK pada umumnya.

6. Rencana Analisis Data

- **ANOVA** tiga arah dengan blok, Type II (desain seimbang, hasilnya sama dengan Type I/III), disertai partial eta-squared sebagai ukuran besar efek.
- **Uji asumsi pada residual:** normalitas (Shapiro-Wilk dan Q-Q plot), homogenitas varians (Levene, median-centered, antar 16 sel), independensi (Durbin-Watson dan plot residual terhadap urutan run), serta plot residual vs fitted.
- **Bila asumsi gagal:** ulangi dengan transformasi arcsin-√ (respon berupa proporsi), atau gunakan macro-F1 sebagai respon pembanding.
- **Uji lanjut:** bila ada interaksi nyata, Tukey HSD pada sel gabungan; bila tidak, Tukey pada faktor utama bertingkat lebih dari dua (C). Tukey mengabaikan efek blok sehingga sedikit konservatif.
- **Respon sekunder** (*pred_acc*) dianalisis dengan model yang sama sebagai pengecekan pada sampel eksternal.
- **Perangkat lunak:** Python (statsmodels, scipy), dengan keluaran *results.csv* yang dapat dianalisis ulang di R, Minitab, atau SPSS.

7. Sumber Daya dan Pengetahuan Awal

Sumber daya	Rincian
Platform	Kaggle Notebook (GPU hanya untuk ekstraksi fitur, training head cukup CPU); Python 3, PyTorch, torchvision, HuggingFace transformers. Biaya tambahan nol.
Waktu (perkiraan)	Ekstraksi fitur 4 backbone sekali jalan ± 15 menit (diperkirakan dari waktu prediksi 0,165 detik/citra di skripsi); 160 run training head diperkirakan beberapa detik sampai belasan detik per run (belum diukur, dicatat saat run pertama); ANOVA hitungan detik.
Bahan dan data	1200 citra training/testing (120 sampel) + 60 citra prediksi; sudah tersedia dari skripsi.
Pengetahuan awal	Pada skripsi, akurasi prediksi berkisar 61,67–91,67%. Terbaik: ViT ImageNet patch 16 (91,67%); HuggingFace patch 16 mencapai 90,00%. Patch 16 selalu ≥ patch 32 pada semua konfigurasi. Dugaan overfitting pada ImageNet dan well-fitting pada HuggingFace perlu diuji ulang karena protokol training kedua jalur berbeda.

8. Alur Pelaksanaan dan Luaran

Langkah	Isi	Luaran
1. Ekstraksi fitur (sekali)	Backbone beku mengubah tiap citra menjadi vektor 768-dim untuk 4 backbone (imgnet16, imgnet32, hf16, hf32), termasuk 60 citra prediksi.	*features/*.npz*
2. Replikasi	Untuk tiap blok: acak sampel, pilih train/test, latih head tiap perlakuan (urutan diacak), catat akurasi dan diagnostik. Bisa dilanjutkan bila sesi terputus.	*results.csv* (160 baris), *splits.csv*
3. Analisis	ANOVA, uji asumsi, Tukey, plot residual dan plot rata-rata.	*anova_table.csv*, *anova_report.txt*, plot

Kolom *results.csv*: block, source, patch, train_n, run_order, seed, n_train_img, n_test_img, train_acc, test_acc, test_macro_f1, loss_final, loss_drop_last10, pred_acc.

9. Perbedaan dengan Pelaksanaan di Skripsi

Aspek	Skripsi	Desain eksperimen ini
Replikasi	1 run per konfigurasi	10 blok per konfigurasi
Unit split	Per citra (foto sampel yang sama dapat tersebar di train dan test)	Per sampel fisik
Test set	Berubah menurut proporsi (20–60%)	Dikunci: 24 sampel (240 citra) tiap blok
Protokol HF vs ImageNet	Berbeda (epoch, lr, dropout head, flip, normalisasi)	Identik

Aspek	Skripsi	Desain eksperimen ini
Preprocessing	Training dan prediksi berbeda (resize 256 + crop 224 vs resize 224 langsung); flip acak ikut di test set HF	Satu transform deterministik per backbone
Seleksi model	Epoch terakhir disimpan	Epoch terakhir (test tidak ikut memilih)
Inferensi statistik	Tidak ada (deskriptif)	ANOVA RAK faktorial, uji asumsi, Tukey

10. Keterbatasan

- **Blok bukan sampel yang benar-benar independen.** Semua blok mengacak ulang 120 sampel yang sama, sehingga test set antar blok saling tumpang tindih. Galat percobaan cenderung diremehkan dan nilai-p cenderung optimis; kesimpulan paling kuat berlaku untuk kumpulan sampel ini. Set prediksi eksternal membantu sebagai pengecekan.
- **Backbone dibekukan.** Kesimpulan berlaku untuk pelatihan head di atas fitur beku (linear probing), bukan fine-tuning penuh.
- **Pencampuran resolusi** pada patch 32 (HuggingFace 384 px vs ImageNet 224 px).
- **Cakupan data sempit:** satu pemasok dan asal kebun, satu kamera dan kondisi pencahayaan; sampel dikurangi menjadi 10 g dari 300 g standar SNI.
- **Test set 24 sampel:** 240 citra berkerumun di 24 sampel fisik, jadi informasi sebenarnya lebih kecil daripada jumlah citranya.

11. Asumsi yang Diverifikasi pada Run Pertama

- Nama file *1T-01.jpg* berarti mutu 1, sampel T, foto ke-01 (20 sampel × 10 foto per kelas). Skrip mencetak validasi struktur sebelum berjalan.
- Citra prediksi (P1A–P1J) berasal dari sampel berbeda dan terpisah dari 120 sampel training/testing; dinilai dari tampilan visual mutu 1, belum dikonfirmasi.
- Notebook HuggingFace patch 32 diasumsikan sama dengan patch 16 selain nama model dan ukuran input (384 px).
- Kolom *loss_drop_last10* mendekati nol di semua backbone; bila tidak, jumlah epoch dinaikkan untuk semua perlakuan.