

Cheat Sheet Materi 2

TI5002 / Analisis Data dan Statistika · Regresi Linier Sederhana & Majemuk

1 · Regresi linier sederhana: model

Model hubungan **dependensi** 2 variabel: 1 prediktor (X) & 1 dependen (Y). Hubungan **tidak deterministik** (statistikal: estimasi rata-rata Y)

Model: $Y = \alpha + \beta x + \epsilon$
garis regresi: $\mu_{Y|X} = \alpha + \beta x$
garis fitted: $\hat{y} = a + bx$; residual $e_i = y_i - \hat{y}_i$

α intercept ($\hat{y}$ saat $x=0$), β slope (perubahan rata-rata Y per 1 satuan x); tanda b = arah hubungan
 ϵ variabel random, **E(ϵ) = 0, berdistribusi normal**, var = σ^2
Random error (ϵ) ≠ residual (e); a, b = estimator α , β
a dan b **variabel random** (dihitung dari y yang random; berubah antar sampel) → dasar inferensi

2 · Least squares & langkah hitung

Pilih a, b yang meminimalkan **SSE = $\Sigma e^2 = \Sigma (y - a - bx)^2$** (turunan thd a, b = 0). Σe biasa selalu 0, jadi tidak jadi kriteria.

$b = S_{xy}/S_{xx} = \Sigma (x-\bar{x})(y-\bar{y}) / \Sigma (x-\bar{x})^2$
 $a = [n\Sigma xy - \Sigma x\Sigma y] / [n\Sigma x^2 - (\Sigma x)^2]$
 $a = \bar{y} - b\bar{x}$

Contoh (1,2)(2,4)(3,5)(4,4)(5,5): $\bar{x}=3$, $\bar{y}=4$; $S_{xy}=6$; $S_{xx}=10$ → $b=0,6$; $a=4-1,8=2,2$; $\hat{y}(6)=2,2+3,6=5,8$. Cek: $\hat{y}=2+3x$, $x=4 \rightarrow 14$.

SSE=2,4; SSR=3,6; SST=6 → $r^2=0,60$; $s^2=2,4/3=0,80$; $t=2,12$; $F=4,5=t^2$.

3 · Penguraian variasi & r²

$SST = SSR + SSE$
 $\Sigma (y-\bar{y})^2 = \Sigma (\hat{y}-\bar{y})^2 + \Sigma (y-\hat{y})^2$
 $r^2 = SSR/SST$
persen variasi Y yang dijelaskan X; $0 \leq r^2 \leq 1$

- Tanpa X, prediksi = $\bar{y}$ (error $y-\bar{y}$); dengan regresi, error berkurang sebesar $(\hat{y}-\bar{y})$
- $s^2 = SSE/(n-2) = \text{MSE}$; s = Std. Error of the Estimate.
- d.o.f. residual = n-2** (2 parameter a, b diestimasi)
- SSR = 60, SSE = 40 → $r^2 = 60/100 = 0,60$

4 · Inferensi β dan α

$\sigma^2_B = \sigma^2 / \Sigma (x-\bar{x})^2$
 $\sigma^2_A = \Sigma x^2 \sigma^2 / [n\Sigma (x-\bar{x})^2]$
 $s^2 = \Sigma (y-\hat{y})^2 / (n-2)$ (MSE)

β : CI: $b \pm t_{\alpha/2} s/\sqrt{S_{xx}}$
uji: **$T = (b - \beta) / (s/\sqrt{S_{xx}})$**

α : CI: $a \pm t_{\alpha/2} s \sqrt{(\Sigma x^2) / (n\S_{xx})}$
uji: **$T = (a - \alpha) / [s \sqrt{(\Sigma x^2) / (n\S_{xx})}]$**

- t Student, d.o.f **n-2**; $H_0: \beta=0$
- Sig. $< \alpha$ → tolak H_0 ; CI tidak memuat 0 ↔ signifikan
- Regresi sederhana: $F = t^2$** (uji F ≡ uji t slope)

5 · Contoh output: investasi vs pajak (n=10)

Output	Nilai	Hitungan
(Const.) B	5033,884	$\hat{y}$ saat pajak 0
Pajak B (SE)	-55,104 (4,385)	$t = -55,104/4,385 = -12,57$
Beta; CI B	-0,976; (-65,2; -45,0)	Beta = r; CI tak memuat 0
ANOVA	SSR 1.951.721,8; SSE 98.855,1; SST 2.050.576,9	df 1; 8; 9
F	157,946	$= t^2 = 157,95$; Sig. 0,000
R, R ²	0,976; 0,952	$r^2 = SSR/SST = 0,952$
Adj. R ²	0,946	
MSE; s	12.356,9; 111,16	98.855,1/8 (bukan 10)

- Tafsir: pajak +1 poin % → rata-rata investasi turun ≈ 55,1 ribu US\$; 95,2% variasi dijelaskan; signifikan
- Prediksi** pajak 10%: 5033,884 - 551,04 = **4482,8** ribu US\$ (x di dalam rentang 5-30%)

6 · Prediksi dengan regresi

CI rata-ran $\mu_{Y|X_0}: \hat{y}_0 \pm t_{\alpha/2} s \sqrt{[1/n + (x_0-\bar{x})^2/S_{xx}]}$
Selang prediksi $Y_0: \hat{y}_0 \pm t_{\alpha/2} s \sqrt{[1 + 1/n + (x_0-\bar{x})^2/S_{xx}]}$

- t, d.o.f n-2. Selang prediksi respons tunggal **lebih lebar** (ada suku "1+"); makin jauh x_0 dari $\bar{x}$, makin lebar
- Jangan prediksi di luar rentang x (ekstrapolasi)

7 · Analisis korelasi

- Mengukur **kekuatan hubungan** dua variabel random (koefisien korelasi ρ ; asosiasi linier)

$r = b \sqrt{(S_{xx}/S_{yy})}$
 $H_0: \rho=0 \rightarrow t = b/(s/\sqrt{S_{xx}})$ atau $t = r\sqrt{(n-2)}/\sqrt{(1-r^2)}$
 $H_0: \rho=p_0 \rightarrow z = (\sqrt{(n-3)/2}) [\ln((1+r)/(1-r)) - \ln((1+p_0)/(1-p_0))]$

- r bertanda sama dengan b, $-1 \leq r \leq 1$, tak bergantung satuan; b bergantung satuan
- Regresi sederhana: Beta terstandar = r; r^2 = koefisien determinasi
- Signifikan (p kecil) ≠ prediksi bagus: cek r^2 (mis. p<0,001 tetapi $r^2 = 0,12 \rightarrow$ hubungan nyata, daya prediksi rendah)

8 · Linierisasi data nonlinier

Fungsi	Transformasi	Regresikan
Ekspensial $y=a e^{bx}$	$y^*=\ln y$	y^* thd x
Power $y=a x^b$	$y^*=\log y$; $x^*=\log x$	y^* thd x^*
Resipikal $y=a+\beta(1/x)$	$x^*=1/x$	y thd x^*
Hiperbola $y=x/(\alpha+\beta x)$	$y^*=1/y$; $x^*=1/x$	y^* thd x^*

- Pertumbuhan relatif konstan (mis. 20%/tahun) → eksponensial: $\ln y$ thd x
- X skewed** (0-100, tapi 80% data di 0-10): pakai **log X**, Y tetap skala awal → tafsir **diminishing return X**

9 · Regresi majemuk: model & matriks

$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k + \epsilon$
 $\hat{y} = b_0 + b_1 X_1 + \dots + b_k X_k$
 $SSE = (y-Xb)'(y-Xb) \rightarrow (X'X)b = X'y \rightarrow b = (X'X)^{-1}X'y$
 $\text{var}(b) = s^2 (X'X)^{-1}$ (SE = akar diagonal)

X: n x (k+1), kolom pertama 1; y: n x 1; ada k+1 parameter.

Sumber	d.f.	MS
Regresi SSR	k	SSR/k
Error SSE	n-(k+1)	SSE/(n-k-1) = s ²
Total SST	n-1	

$R^2 = SSR/SST$; $F = MSR/MSE$; $R^2_{adj} = 1 - ((n-1)/(n-k-1)) (R^2)$
rumus adjusted R² & F standar; di slide: adjusted R² = R² dengan penalti

Contoh Panjang bayi n=42, k=5: SSR 28,164; SST 50,786 → $R^2=0,555$; adj=1-0,445 x 41/36=0,493; MSR=5,633; MSE=2,622/36=0,628 → **F=8,96**; s=0,79. IP (n=8, k=2): $R^2=0,976$; adj 0,966; F=100,0.

10 · Tujuan, desain & 6 tahap

Prediksi	Penjelasan
maksimal kemampuan prediksi (mis. time series), boleh korbankan interpretasi	model berbasis teori ; baca: kepentingan variabel, jenis hubungan, interrelasi antar IV

- Hubungan **statistikal** = estimasi rata-rata Y; **fungsional** = nilai eksak
- Pilih variabel berdasar kerangka teori. **Specification error**: mengikutkan variabel tak relevan atau melupakan variabel relevan
- Sampel minimum **5 x jumlah IV** (Hair, 1998): 7 IV → 35
- 1. Masalah penelitian (tujuan, pilih var.)
- 2. Desain (sampel, power; transformasi, dummy, polynomial, interaksi)
- 3. Asumsi
- 4. Teknik estimasi (spesifikasi peneliti / sequential)
- 5. Signifikansi (R^2 , SE est., koef.) & interpretasi (beta, multikolinearitas)
- 6. Validasi (split sample, PRESS)

11 · Asumsi & pola residual

linieritas	variansi error konstan (homoskedastis)
independensi error	error normal

ideal (null plot) nonlinear heteroskedastis

- Normalitas dikanakan pada **error**, bukan pada tiap variabel independen
- Plot residual vs $\hat{y}$: acak = baik; lengkung = tak linier; corong = heteroskedastis
- Pelanggaran linieritas → transformasi (eksponensial, power, resipikal, hiperbola)

12 · Variabel dummy & interaksi

- Variabel nonmetrik dengan **k kategori** → **k-1 dummy** (indicator coding atau effect coding); kategori semua-0 = **kelompok kontrol**
- Koefisien dummy = **selisih rata-rata** kategori itu thd kategori acuan (variabel lain tetap)

Contoh Panjang D3,S1,S2,S3 → 3 dummy. IP = 2,0 + 0,2 Jambel + 0,3 Gender (perempuan=1): mahasiswa 5 jam = 2,0+1,0+0,3 = **3,3**; laki-laki = 3,0.

Moderasi: $Y = b_0 + b_1 X_1 + b_2 X_2 + b_3 X_1 X_2$
 b_3 = efek moderasi: efek X1 berbeda antar kelompok X2. Uji b_3 .

Mis. eksposur iklan lebih kuat pada perempuan: penjualan = $b_0 + b_1 \text{Eksposur} + b_2 \text{Gender} + b_3 \text{Eksposur} \times \text{Gender}$. $b_3 = +0,1 \rightarrow$ jam belajar 10% lebih efektif bagi mahasiswa.

13 · Estimasi: enter vs sequential

- Enter** (confirmatory): semua variabel masuk; kekurangan: tidak **parsimoni**
- Sequential** (stepwise, forward/backward): variabel sesedikit mungkin, hanya yang signifikan
- Uji F** = model keseluruhan (semua IV bersama); **uji t** = tiap IV. Model signifikan belum tentu semua IV signifikan; ekstrem: model signifikan tanpa satu IV signifikan → multikolinearitas tinggi
- Partial correlation**: korelasi X_i -Y setelah efek IV lain dikeluarkan dari X_i dan Y

Contoh Panjang bayi (enter): F=8,964 (Sig. 0,000); $R^2=0,555$. Sig.: usia hamil 0,000; rokok B=-0,022 (0,042); tinggi ibu 0,011; usia ibu 0,719; tinggi ayah 0,997 → yang terakhir tidak signifikan. Stepwise: masuk usia hamil → tinggi ibu → rokok.

14 · Beta, multikolinearitas, VIF

- Koef. regresi (B) peka satuan; **Beta** (dari nilai standardisasi) bisa membandingkan kontribusi IV berbeda satuan
- Efek multikolinearitas**: sulit memisahkan efek tiap IV; membatasi R^2 ; singularity → koef. salah estimasi

VIF = 1 / tolerance			
tolerance < 0,1 atau VIF > 10 = bermasalah			
tolerance	0,5	0,05	0,839-0,929
VIF	2	20 (>10)	1,08-1,19 (aman)

Deteksi: matriks korelasi Pearson, tolerance, VIF.
Remedial: buang IV berkorelasi tinggi · model hanya untuk prediksi · pakai korelasi sederhana IV-DV · metode lebih canggih

15 · Validasi & kehati-hatian prediksi

- Validasi**: sampel baru, atau data yang ada: split (80% estimasi : 20% validasi) / bootstrapping
- Model lebih banyak IV selalu R^2 lebih besar → tak adil; pakai **adjusted R²** (penalti, prinsip parsimoni); $\text{adj} \leq R^2$
- Prediksi: sampel bervariasi · hubungan berubah seiring waktu · **jangan di luar rentang IV**

16 · Observasi berpengaruh (influential)

3 jenis: **outlier** (residual besar), **leverage** (nilai IV unik), **influential** (efek tidak proporsional pada hasil). Outlier tak harus influential.

- Residual: normal; standardized; deleted; studentized; studentized deleted
- Hat value** (diag. $H_i = Y_i/Y$) besar jika > **2p/n** (sampel besar), > **3p/n** (kecil); atau jarak Mahalanobis
- Cook's D** = $\Sigma (\hat{y}_{(i)} - \hat{y}_i)^2 / ((p+1)s^2) > 4/(n-p-1)$ atau > 1. n=42, p=5: 4/36 = **0,111**
- SDFBETA**: ± 1 atau ± 2 (sampel kecil); $\pm 2/\sqrt{n}$ (tertulis di slide)
- COVRATIO**: $1 \pm 3p/n \cdot \text{SDFFIT}$: $2\sqrt{((k+1)/(n-k-1))}$