

Cheat Sheet Materi 3

TI5002 / Analisis Data dan Statistika · Analisis Regresi Logit

1 · Mengapa logit, bukan OLS?

- Regresi linier majemuk: Y harus **metrik**
- Y **nominal** (sukses/gagal) → asumsi **normalitas error dilanggar**: untuk x tertentu error hanya punya 2 kemungkinan nilai
- Plot kelompok usia vs proporsi CHD tidak linier, membentuk **huruf S** → didekati dengan **fungsi logistik**


Skala Y	Model
metrik	regresi linier
nominal biner	logit biner
nominal > 2 kategori	multinomial logit
ordinal > 2 kategori	ordered multinomial logit

2 · Fungsi logistik & transformasi logit

$$E(Y|X) = \pi(x)$$
$$\pi(x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$$
$$g(x) = \ln\left[\frac{\pi(x)}{1 - \pi(x)}\right] = \beta_0 + \beta_1 x$$

$\pi(x)$ selalu di antara 0 dan 1. $g(x) = \ln(\text{odds})$, linier dalam parameter.

Properti logit $g(x)$: berbentuk linier · kontinu · bernilai $-\infty$ sampai $+\infty$



3 · Estimasi: maximum likelihood

- Parameter β **tidak** bisa dengan least square; dipakai **maximum likelihood**
- Cari β yang memaksimalkan $l(\beta)$; persamaan diselesaikan **numerik** (software)

$$l(\beta) = \prod \pi(x_i)^{y_i} [1 - \pi(x_i)]^{1 - y_i}$$
$$L(\beta) = \ln l(\beta) = \sum \{ y_i \ln \pi(x_i) + (1 - y_i) \ln [1 - \pi(x_i)] \}$$

maks. $L(\beta)$ bila: $\sum [y_i - \pi(x_i)] = 0$
dan $\sum x_i [y_i - \pi(x_i)] = 0$
di-log-kan agar mudah didiferensiasi

4 · Uji signifikansi parameter

Pertanyaan: apakah model dengan variabel x memberi informasi lebih banyak daripada model tanpa x?

$$D = -2 \ln \left[\frac{L(\text{fitted})}{L(\text{saturated})} \right]$$
$$G = D(\text{tanpa var}) - D(\text{dengan var}) = -2 \ln \left[\frac{L(\text{tanpa})}{L(\text{dengan})} \right]$$

saturated = jumlah parameter sama dengan jumlah data point

- $H_0: \beta_1 = 0 \rightarrow G \sim \chi^2$ dengan d.o.f = 1 (kritis 3,84 pada α 5%)
- Wald:** $W = \beta_1 / SE(\beta_1)$, normal secara asimptotis (di SPSS dilaporkan W^2 , df = 1)
- Jika Sig. < 0,05 → tolak H_0 : variabel berpengaruh signifikan terhadap peluang Y

Contoh CHD (n=100): LL model = -53,677; LL tanpa AGE = -68,331 → $G = -2(-68,331 + 53,677) = 29,31 > 3,84 \rightarrow \beta_1$ signifikan. $W = 0,111/0,0241 = 4,61$ (konstanta: -5,309/1,1337 = -4,68).

5 · Kebaikan model

$$R^2_{\text{logit}} = \frac{(-2LL_{\text{null}} - (-2LL_{\text{model}}))}{(-2LL_{\text{null}})}$$

pseudo R^2 . Ukuran lain: statistik Hosmer-Lemeshow

Contoh $-2LL_{\text{null}} = 136,662$; $-2LL_{\text{model}} = 107,353 \rightarrow R^2 = 29,309/136,662 = 0,214$

Tabel klasifikasi (cut value 0,5): akurasi = (benar)/(total)

Model (n=60)	benar	akurasi
0: tanpa variabel	38/60	63,3%
enter (4 var)	(32+10)/60	70,0%
forward langkah 2	(31+13)/60	73,3%

Output enter: $-2LL = 65,478$; Cox & Snell 0,200; Nagelkerke 0,273.

6 · Interpretasi: odds & Exp(B)

$$\text{odds} = \frac{P(Y=1)}{P(Y=0)} = e^{\beta'x}$$
$$g(x) = \ln(\text{odds})$$

naik 1 satuan x → odds $\times e^{\beta}$ (= Exp(B))

Exp(B)	Arti
> 1 (B positif)	variabel naik → odds Y=1 naik
< 1 (B negatif)	odds turun
= 1 (B = 0)	tidak berpengaruh

- Parameter signifikan $\neq 0 \rightarrow$ variabel berpengaruh pada probabilitas Y
- Interpretasi mirip regresi majemuk; efek pada odds bersifat **perkalian**

Contoh odds $P=0,8$: $0,8/0,2 = 4$. $g = 0 \rightarrow \pi = e^0/(1+e^0) = 0,5$. Kenaikan 10 th: $e^{0,111 \times 10} = e^{1,11} = 3,03 (= 1,117^{10})$.

7 · Prediksi dari model (langkah hitung)

1. Hitung logit: $\hat{g} = b_0 + b_1 x$

2. Odds = $e^{\hat{g}}$

3. Peluang $\hat{\pi} = e^{\hat{g}}/(1+e^{\hat{g}})$

Contoh $\hat{g}(x) = -5,309 + 0,111 \times \text{AGE}$.
AGE = 50: $\hat{g} = 0,241$; odds = 1,27; $\hat{\pi} = 0,56$. Peluang CHD menurut usia: 20 → 0,04 · 30 → 0,12 · 40 → 0,30 · 50 → 0,56 · 60 → 0,79

Peluang naik tidak konstan per tahun (kurva S), tetapi odds naik $\times 1,12$ per tahun.

8 · Contoh kasus: minat perusahaan (n=60)

Y = minat (1 = tidak, 2 = berminat; 38 vs 22). X: ukrn (karyawan), pdptn (juta USD), usia (th), jmlproy.

Model 0 (tanpa X): $B = -0,547$; $\text{Exp}(B) = 0,579 = 22/38$ (odds berminat).

enter	B	Sig.	Exp(B)
ukrn	0,089	0,024	1,093
pdptn	0,161	0,646	1,175
usia	0,914	0,020	2,494
jmlproy	-0,020	0,900	0,980
konstanta	-10,397	0,002	0,000

Hanya **ukrn** & **usia** signifikan: +1 karyawan → odds $\uparrow$ 9,3%; +1 th usia → odds $\times$ 2,5.

Forward: langkah 1 masuk ukrn (B 0,064; p 0,023) → langkah 2 masuk usia (ukrn 0,084, p 0,006; usia 0,934, p 0,016). pdptn & jmlproy tidak masuk.

9 · Jika-maka (cepat)

- Jika Y metrik → regresi linier; jika Y biner → **logit**; > 2 kategori → **multinomial**; ordinal → **ordered**
- Jika Sig. < 0,05 → tolak $H_0: \beta = 0$ (signifikan)
- Jika $G > \chi^2(1; 0,05) = 3,84 \rightarrow \beta_1$ signifikan
- Jika $\text{Exp}(B) > 1 \rightarrow$ odds naik; < 1 → odds turun
- Jika $-2LL$ model jauh lebih kecil dari $-2LL$ null → pseudo R^2 besar
- Jika ingin variabel signifikan saja → forward/stepwise; semua variabel → enter