

Cheat Sheet Materi 5

TI5002 / Analisis Data dan Statistika · Analisis Cluster

1 · Tujuan & karakteristik

- Tujuan:** mengelompokkan **objek** (orang, perusahaan, produk) ke kelompok yang *manageable* memakai atribut pengelompok tertentu
- Anggota satu cluster **sangat mirip**; antar cluster **berbeda berarti**

deskriptif eksploratori solusi tidak unik

selalu menghasilkan cluster

sangat tergantung variabel pengelompok

Cluster selalu terbentuk, walau struktur 'sebenarnya' ada atau tidak.

2 · Alur metodologi

- Ambil **p** variabel pada **n** objek → matriks **n x p**
- Ubah jadi **matriks similaritas n x n** (pasangan objek)
- Pilih algoritma pengelompokan

1. hierarkis: top-down (divisive) / bottom-up (agglomerative)

2. non-hierarkis 3. kombinasi

Dasar: **similarity** (kesamaan) atau **dissimilarity** (ketidaksamaan). **Ukuran similaritas**: ukuran **jarak** · koefisien **korelasi** · koefisien **asosiasi**.

Jarak Euclidean $d(i,j) = \sqrt{\sum_k (x_{ik} - x_{jk})^2}$

Contoh (0,0)-(3,4): $\sqrt{(9+16)} = 5$. B(4,5)-G(6,4): $\sqrt{(4+1)} = 2,24$.


3 · Matriks jarak contoh (7 objek, 2 variabel)

	A	B	C	D	E	F	G
V1, V2	3,2	4,5	4,7	2,7	6,6	7,7	6,4
A	0	3,16	5,10	5,10	5,00	6,40	3,61
B		0	2,00	2,83	2,24	3,61	2,24
C			0	2,00	2,24	3,00	3,61
D				0	4,12	5,00	5,00
E					0	1,41	2,00
F						0	3,16

Pasangan paling mirip (jarak terkecil) digabung lebih dulu: E-F (1,41).

4 · Metode hierarkis (linkage)


Metode	Jarak antar cluster
Single (nearest neighbor)	jarak terpendek dua anggota
Complete (furthest neighbor)	jarak terjauh
Average (between-groups)	rata-rata semua pasangan
Ward (error sum of squares)	meminimalkan variasi dalam cluster
Centroid	jarak antar centroid (pusat)



Contoh {E,F} vs G, $d(E,G)=2,00$ & $d(F,G)=3,16$: single = **2,00**; complete = **3,16**; average = $(2,00+3,16)/2 = 2,58$.

Agglomerative: n objek → **n-1 tahap** (10 objek: 9 tahap; 15 industri: 14 tahap). Tiap tahap mengurangi 1 cluster.

5 · Dendrogram (single linkage, 7 objek)



- Dendrogram menunjukkan **urutan & jarak** penggabungan; angka bulat = urutan tahap
- Makin ke kanan = penggabungan makin tidak mirip

6 · Non-hierarkis & input analisis


Non-hierarkis: sequential threshold parallel threshold optimizing

Hal terkait input:

- Satuan** yang digunakan → jika skala/satuan berbeda, **standarisasi** (variabel besar mendominasi jarak)
- Adanya **outlier**
- Variabel pengelompok** (menentukan hasil)
- Dependensi** antar variabel

7 · Menentukan jumlah cluster

- Peneliti telah **menetapkan** jumlahnya
- Berdasar **variabilitas error** (deviasi dari pusat cluster) lewat **koefisien aglomerasi**
- Berdasar **kemudahan interpretasi**



Berhenti sebelum lonjakan besar: koefisien naik 5,621 → 9,483 di tahap 13, maka pakai hasil sesudah tahap 12 → $15 - 12 = 3$ cluster.

Tahap 1: objek 8 & 15 digabung (koef. 0,773) = pasangan paling mirip. Koefisien naik terus karena yang digabung makin berbeda.

8 · Interpretasi cluster (contoh 15 UKM)

Pend. = pendapatan (miliar Rp); Prod. = jumlah produk. Cluster 1 = perusahaan 4,6,7,8,9,10,11,15.

Centroid = rata-rata tiap variabel dari anggota cluster; lalu beri **nama** sesuai profil & tujuan studi.

Cluster	Kary.	Pend.	Usia	Prod.
1 (4,6-11,15)	33,50	2,27	3,31	3,38
2 (1,2,12,14)	49,25	1,73	6,75	3,75
3 (3,5,13)	47,33	4,23	4,50	6,33

- C1: perusahaan **baru berkembang**
- C2: **mulai menurun** performansinya (usia tertinggi)
- C3: **sedang berkembang** (pendapatan & produk tertinggi)

Contoh Usia C2: $(7+7+6+7)/4 = 6,75$. Produk C3: $(7+7+5)/3 = 6,33$ ($\approx 1,9 \times$ C1). Usia 2,4,6 → centroid 4.

9 · Validasi

- Bandingkan hasil **algoritma berbeda**
- Bagi sampel** menjadi dua
- Pakai **variabel yang tidak dipakai** untuk mengelompokkan
- Simulasi**

10 · Cluster vs teknik lain

Bandingan	Fokus / titik awal
Cluster	mereduksi data objek ; mulai dari grup belum berdiferensiasi, lalu dibuat sub-grup yang dapat dibedakan
Faktor / komponen utama	mereduksi variabel
Diskriminan / logit	mulai dari grup yang sudah jelas (<i>well defined</i>); pertanyaan: bagaimana grup dibedakan

- Jika **tidak ada label grup** → cluster
- Jika grup **sudah berlabel** (mis. gagal bayar/lancar) → diskriminan / regresi logistik
- Jika ingin meringkas **variabel** → analisis faktor